

Entwicklung eines klassischen Kreuzungsdetektors

Studienarbeit

Studiengang Informatik

Duale Hochschule Baden-Württemberg Stuttgart

Reinhold Brant

Eingereicht am: 08.06.2026

Matrikelnummer, Kurs: 7261389, STG-TINF23ITA

Betreuer an der DHBW: Tom Freudenmann

Inhalt

1 Abstract	1
2 Einleitung	2
2.1 Problemstellung	2
2.2 Kreuzungen	3
3 Stand der Technik	5
3.1 Herausforderungen in der Detektion	5
3.2 Klassischer Ansatz	6
3.3 Deep-Learning-basierter Ansatz	7
3.3.1 CNN basierte Detektion	7
3.3.2 Linien-basierte Deep-Learning-Methoden	7
3.4 Vergleich	7
4 Technischer Kontext	9
4.1 Das Fahrzeug	9
4.1.1 Karosserie	9
4.1.2 Kamera	10
4.1.3 NUC	10
4.2 Modulübersicht	10
4.2.1 Camera Preprocessing	10
4.2.2 State Machine	10
4.2.3 Vision	11
4.2.4 Perzeption und Planung	12
4.2.5 Andere Module	13
4.3 Softwarearchitektur	13
4.3.1 ROS2	13
4.3.2 Bibliotheken	13
4.3.3 Struktur	14
4.3.4 Moduleinordnung im Gesamtsystem	15
5 Entwicklung des Moduls	16
5.1 Bildvorverarbeitung	16
5.1.1 Bildperspektive	16
5.1.2 Bildentzerrung	18
5.1.3 Morphologisches Öffnen und Schließen	20
5.1.4 Reflektionsminimierung	22

5.1.5	Kontrastoptimierung mit CLAHE	22
5.2	Kantenerkennung	23
5.2.1	Canny Edge Detector	23
5.3	Linienextraktion	25
5.3.1	Line Segment Detector	25
5.3.2	Hough Transformation	26
5.3.3	Pipeline für die Linienerkennung	29
5.4	Linienvorverarbeitung	29
5.4.1	Linienlängenfilter	29
5.4.2	Region of Interest Filter	31
5.4.3	Linienfusion	31
5.4.4	Winkelfilter	33
5.4.5	Pipeline für die Linienvorverarbeitung	34
5.5	Haltelinienklassifikation	34
5.5.1	Primitive Ermittlung der Ego- und Opplinie	34
5.5.2	Kreuzungsmittenbasierte Detektion	35
5.5.3	Sektorbasierte Detektion der rechten und linken Haltelinie	36
5.5.4	Zentrumsbasierte Detektion aller Haltelinien	38
5.6	Berechnung des Kreuzungszentrums	38
5.6.1	Primitive Bestimmung der Kreuzungsmitte	38
5.6.2	Algorithmische Kreuzungsmittendetektion	39
5.6.3	Hybrider Ansatz zur Kreuzungsmittenberechnung	42
5.6.4	Pipeline zur Kreuzungszentrumserkennung	42
5.6.5	Erweiterung der Kreuzungsmitte	43
5.7	Klassifizierung der Linienart	44
5.7.1	Linienausschnitt	44
5.7.2	Weißwertberechnung	45
5.7.3	Gap-Detektion	46
5.7.4	Pipeline zur Klassifizierung der Linienart	47
5.8	Heading der Straße	48
5.8.1	Gaussian Mixture Model mit Expectation Maximization	48
5.8.2	Deep Learning basierter Ansatz	49
5.8.3	Histogrammbasierter Ansatz	49
5.8.4	Pipeline zur Headingwinkel Berechnung	50
5.9	Postprocessing der Ego- und Opplinie	50
5.9.1	Linienpräzisierung	51
5.9.2	Linienumgebung	52
5.9.3	Validierung von Querlinienpaaren	52
5.10	Plausibilisierung vertikaler Haltelinien	53

5.11 Ergebnisaggregator	53
5.12 Bild zu Welt Transformation	55
6 Konzeption einer Sperrflächenerkennung	56
7 Evaluation	58
7.1 Labeling der Daten	58
7.2 Metriken	59
7.2.1 Primäre Performance-Metriken	59
7.2.2 Verteilungsmetriken	59
7.2.3 Qualitative Fehlermetriken	60
7.3 Datensatz 1	60
7.3.1 Evaluation der Kreuzungserkennung (Baseline)	60
7.3.2 Auswertung und Diskussion	61
7.4 Vollständige Fahrt mit First Contact Labeling	62
7.4.1 Evaluation der Kreuzungserkennung (First Contact)	62
7.4.2 Auswertung der Evaluation First-Contact	63
7.5 Datensatz 2	64
7.5.1 Evaluation der Kreuzungserkennung (Datensatz 2)	64
7.5.2 Auswertung der Evaluation Datensatz 2	65
8 Fazit	66
8.1 Kritische Reflexion	66
8.1.1 Positive Ergebnisse	66
8.1.2 Herausforderungen	67
8.2 Ausblick	68
8.2.1 Erweiterungspotenzial	68
8.2.2 Langfristige Perspektiven	68
A Literatur	70
B Glossar	73



Abstract

Bei der CAuDri-Challenge - CAuDri steht für Cognitive Autonomous Driving - treffen sich verschiedene Hochschulgruppen aus ganz Deutschland, um ihre autonomen Modellfahrzeuge in zwei Disziplinen, dem Free Drive und dem Obstacle Evasion, gegeneinander antreten zu lassen. Dabei muss das Fahrzeug auch Kreuzungen durchfahren können. In der aktuellen Version des Fahrzeugs werden Schilder an der Kreuzung erkannt und nach einer bestimmten Strecke hinter diesen gestoppt, um kurz vor der Haltelinie zum Stehen zu kommen. Eine Verbesserung dieses Systems ist eine Haltelinienerkennung. Diese ermöglicht ein präzisen Haltevorgang an der Haltelinie. Zusätzlich erfordern es die aktuellen Disziplinen der CAuDri-Challenge nur, an der Kreuzung den Spuren der Vorfahrtsstraße zu folgen. In einer neuen Disziplin der CAuDri-Challenge sollen aber beliebige Abbiegevorgänge an der Kreuzung möglich sein.

Ziel der Arbeit ist, eine Haltelinien- und Kreuzungserkennung zu entwickeln, die Abbiegespuren zuverlässig in vielen Situation erkennt. Außerdem soll es die Haltelinienerkennung ermöglichen, exakt an der Haltelinie zum Stehen zu kommen. Das gesamte Modul soll eine regelkonforme Durchfahrt in alle Kreuzungsrichtungen zuverlässig ermöglichen. Das Modul muss unabhängig vom Untergrund beziehungsweise anderen Störquellen robust und zuverlässig Haltelinien und Spuren erkennen.



Einleitung

2.1 Problemstellung

In der Caudri Challenge durchfährt das Fahrzeug autonom eine Strecke. Dabei nutzt es eine Kamera, um zu navigieren. In der Disziplin Free Drive muss das Fahrzeug so lange wie möglich ohne Steuerung von außen auch Kreuzungen korrekt erkennen und durchfahren. Um dies zu erreichen, muss die Kreuzungserkennung alle Haltelinien innerhalb der Kreuzung korrekt erkennen und anhand dieser die Kreuzung klassifizieren, bevor das Fahrzeug diese durchfahren kann.

Das Modul gibt die gewonnenen Informationen über die Kreuzung nach der Berechnung an das Pfadplanungsmodul weiter, welches anschließend den korrekten Fahrtweg durch die Kreuzung berechnet.

Das Modul wird als klassische Kreuzungserkennung implementiert und nutzt dabei keine Deep Learning Verfahren. Das hat einige Vorteile für das Deployment des Moduls auf dem Fahrzeug. Zum Einen sind Ergebnisse des Moduls einfach zu interpretieren, da die Berechnungen des Moduls vollständig regelbasiert getroffen und nicht durch ein Modell berechnet werden. Außerdem können Parameter wie etwa für Winkelfilter, Längenfilter und andere regelbasierte Systeme besser angepasst werden, um Ergebnisse zu optimieren. Dazu wäre für einen Deep Learning Ansatz ein aufbereiteter Datensatz mit sauberen Labels notwendig, was durch den klassischen Ansatz wegfällt.

2.2 Kreuzungen

Um eine zuverlässige Kreuzungserkennung auf dem Fahrzeug zu implementieren werden zuerst die Kreuzungen betrachtet, die das System erkennen soll. Innerhalb der Caudri-Challenge gibt es eine Menge an Kreuzungen, die sich durch die Position der Haltelinien, der Art der Haltelinien und der Straßenführung innerhalb der Kreuzung unterscheiden. Diese sind dokumentiert.




Abbildung 1 — Kreuzungen der CauDri-Challenge [1]

Die zu erkennenden Kreuzungen sind folgendende:

- Ego- und Gegenspur Haltelinien durchgezogen
- Ego- und Gegenspur Haltelinie gestrichelt
- Gestrichelte Haltelinien an allen Spuren der Kreuzung
- Abknickende Vorfahrtsstraße links mit durchgezogenen Linien in der Ego- und Gegenspur
- Abknickende Vorfahrtsstraße links mit gestrichelten Haltelinien in der Ego- und Gegenspur
- Abknickende Vorfahrtsstraße links mit durchgezogener Haltelinie in der Gegenspur und der rechten Spur

Die zu erkennenden Kreuzungen sind standardisiert und sehen innerhalb der Strecke stets gleich aus [1].

3

Stand der Technik

In der Praxis sind Kreuzungserkennungen essenziell, um einen autonomen Betrieb eines Fahrzeugs zu ermöglichen. Um Kreuzungen klassifizieren zu können, muss das Fahrzeug in zuerst die Haltelinien erkennen, die zu der Kreuzung gehören. Das autonome Fahrzeug muss berechnen, wann und ob es an der Kreuzung halten soll und um welche Art der Kreuzung es sich handelt.

3.1 Herausforderungen in der Detektion

In der Detektion von Straßenmarkierungen kommt es innerhalb einer realen Fahrumgebung zu Problemen, die die Qualität der Erkennung erheblich beeinflussen können.




Abbildung 2 — Störfaktoren bei der Linienerkennung [2]

. Dabei können Markierungen in ihren geometrischen Eigenschaften unterschiedlich sein (siehe Abbildung 2 (b)), schlechte Lichtbedingungen oder Überdeckungen durch

Objekte (Abbildung 2 (e, i)) oder schlechte Sichtbedingungen durch Regen, Schnee oder Nebel seine (Abbildung 2 (f, h)) [2].

Dabei können die technischen Ansätze, um Haltelinien zu erkennen, in zwei Kategorien unterteilt werden. Die erste ist (1) klassischer feature-basierter Ansatz und der (2) deep-learning-basierte Ansatz. Beide weisen Vorteile und Nachteile auf. Während der klassische Ansatz kein Vorbereiten eines Datensatzes und kein Trainieren eines Modells voraussetzt, kann der Ansatz anfälliger für Störfaktoren auf der Straße sein, wie etwa Objekte über der Haltelinie (Blätter, Erde, Dreck). Der deep-learning-basierte Ansatz kann eine höhere Robustheit gegenüber Störfaktoren erzielen, kann diese aber auch nicht im Gesamten ausschließen [3].

Innerhalb der CauDri-Challenge sind geometrische Eigenschaften der Linien genormt. Es ist aber zu erwarten, dass die Detektion der Linien durch Lichtreflektionen der Sonne erschwert wird.

3.2 Klassischer Ansatz

Der klassische Ansatz einer Haltelinienerkennung umfasst regelbasierte Algorithmen, die in mehreren Schritten Kanten erkennen, klassifizieren und filtern. Dabei gilt die Transformation des Bildes in die Vogelperspektive (auch birds-eye-view oder BEV) durch Inverse Perspective Mapping als Standard [4]. Dabei werden perspektivische Verzerrungen im Bild rückgängig gemacht, sodass man die geometrischen Attribute der Linien und deren Beziehungen untereinander für eine Klassifikation nutzen kann (Abbildung 5). Wird ein klassisches Bild verwendet, können beispielsweise Winkelbeziehungen zwischen Linien nicht mehr verwendet werden. Auch die Winkelausrichtungen, die Längen und die Dicke der Linien selbst können inkonsistent sein.

Viele klassische Ansätze verwenden nun Algorithmen zur Kantenerkennung, die auf der Berechnung von Intensitätsunterscheiden zwischen Pixeln aufbauen [4]. Diese werden innerhalb einer Region Of Interest (ROI) erkannt. Aus dem gewonnenen Graustufenbild werden nun Linien erkannt. Dafür werden in der Regel Algorithmen wie die Hough-Transformation verwendet [4], [5]. Es können folgend Farbwerte, Dicke, Länge und anderen geometrische Eigenschaften der Linien und deren geometrischen Beziehung untereinander (beispielsweise Schnittwinkel) genutzt werden, um Haltelinien zu klassifizieren [4].

3.3 Deep-Learning-basierter Ansatz

Der bereits beschriebene klassische Ansatz zur Detektion von Haltelinien erreicht bei Einwirkung der in Abbildung 2 gezeigten Störfaktoren ungenaue Ergebnisse. Der deep-learning-basierte Ansatz kann durch ein Training auf einer großen Datenbasis robustere Ergebnisse liefern [3].

3.3.1 CNN basierte Detektion

Eine Methode der Detektion beruht auf dem Nutzen von CNNs (Convolutional Neural Networks) zur Extraktion von Features aus Bildern. In einem von Lin et al. vorgestellten System wird ein AdaBoost-Klassifizierer mit einem Convolutional Neural Network (CNN) zu einem hybriden System verbunden [6]. Der AdaBoost-Klassifizierer fungiert dabei als Regions-Proposal-Generator und erzeugt Kandidatenbereiche, die anschließend vom CNN klassifiziert werden. Dies ermöglicht einen effizienten Zweilagigen-Filter, der falsche Positive reduziert und gleichzeitig hohe Verarbeitungsgeschwindigkeit beibehält. Eine wichtige Verbesserung stellt die Hard-Negative-Mining-Technik dar, die iterativ falsche Positive sammelt und das Modell darauf nachtrainiert, diese zu eliminieren. Dies führt zu einer signifikanten Reduktion von False Alarms [6].

3.3.2 Linien-basierte Deep-Learning-Methoden

Eine neuere Methode stellt die Verwendung von Linien-Detektoren als Zwischenmerkmale dar. Statt direkt mit Bounding-Boxen zu arbeiten, werden Linien als Segmente mit Dicke modelliert. Dies ermöglicht eine präzisere Erfassung der eigentlichen Haltelinien-Geometrie und reduziert Annotationsaufwand gegenüber pixelbasierten Methoden. Ein zweistufiger Ansatz kombiniert dabei einen Liniendetektor mit einem Stop-Linien-Detektor. Der Liniendetektor leitet den Prozess ein und hilft dem Netzwerk, sich auf Fahrbahnmarkierungen zu konzentrieren. Multi-Task Learning mit mehreren Verlustfunktionen (Zentrum-Verlust, Verschiebungs-Verlust, Dicke-Verlust und Segmentierungs-Verlust) verbessert die Robustheit des Modells. Diese Kombination ermöglicht sowohl effiziente Berechnung als auch hohe Genauigkeit unter komplexen Bedingungen [3]. TODO: nochmal drüberschauen.

3.4 Vergleich

Allgemein ist zu vermuten, dass der deep-learning-basierte Ansatz eine robustere Liniendetektion erlaubt. Um ein solches System umzusetzen, müssen vorerst Daten

gesammelt und aufbereitet werden, sodass man mit diesen Daten Modelle trainieren kann. Für den zugrunde liegenden Fall der Detektion innerhalb der CauDri-Challenge wird angenommen, dass eine Detektion von Haltelinien zur Klassifizierung der Kreuzung auch ohne das Training von Modellen durch einen klassischen Ansatz erreicht werden kann, da die Strecke innerhalb der Challenge standardisiert und genormt ist, sowie keine starken Störfaktoren wie Wetter, Schmutz oder Überdeckungen aufweist. Ein Störfaktor ist die Lichtverschmutzung auf der Strecke, was aber durch eine passende Bildvorverarbeitung als lösbar angesehen wird.

Die Implementierung des klassischen Ansatzes ist ferner aufgabenbedingt, ist aber im Kontext der CauDri-Challenge auch, wie zuvor erläutert, ein valider Ansatz.

4

Technischer Kontext

Im folgenden Kapitel wird die Rahmenarchitektur des Fahrzeugs sowie der Software im Detail erläutert und der zu implementierende Detektor als Modul in diesem Gesamtsystem erklärt.

4.1 Das Fahrzeug

Bei dem Fahrzeug des DHBW SmartRollerz Teams der DHBW, bei dem das Kreuzungs-erkennungsmodul installiert werden soll, handelt es sich um ein vom Team selbst modelliertes RC-Fahrzeug (siehe Abbildung 3).



Abbildung 3 — Modell SmartyV6 Fahrzeug (Smartrollerz)

4.1.1 Karosserie

Bei der Karosserie des Fahrzeugs handelt es sich um ein vom entsprechenden Team entworfenes Modell, welches mit einem 3D-Drucker gefertigt wird (siehe Abbildung 3). Die Karosserie dient in erster Linie zum Schutz der Elektronik des Fahrzeugs.

Herausforderungen beim Entwurf der Karosserie sind es, den Anforderungen anderer Schnittstellenteams zu genügen und dabei eine Balance aus Praktikabilität, Leistung und dem Erfüllen der CauDri-Regeln zu finden [7].

4.1.2 Kamera

Damit das Fahrzeug die eigene Umgebung wahrnehmen kann, ist eine Kamera mit Fischaugenlinse verbaut (siehe Abbildung 3), um ein maximal mögliches Sichtfeld zu gewährleisten. Diese liefert das Bild für alle Perceptionmodule, die in Abschnitt 4.2 näher erläutert werden.

4.1.3 NUC

Die NUC (Next Unit of Computing) ist ein kleiner PC, der es erlaubt, durch eigene Erweiterungen eine Recheneinheit für den Gebrauch in spezifischen Anwendungsfällen, wie etwa dem RC-Fahrzeug. Auf der NUC laufen alle relevanten Softwaremodule des Fahrzeugs.

4.2 Modulübersicht

Der Modulstack des Fahrzeugs lässt sich in die Kategorien (1) Vision, (2) Perception & Planning, (3) Elektronik & Embedded und (4) Simulation unterteilen. Wichtig sind aber auch Module, die alle anderen Module unterstützen. So sind die Camera Preprocessing und die State Machine Module von hoher Wichtigkeit.

4.2.1 Camera Preprocessing

Das Camera Preprocessing Modul wandelt das Rohbild aus der am Fahrzeug installierten Kamera zu einem für anderen Module brauchbaren Bild um. Es implementiert mit Einbezug der Kamerakalibrierung die Transformationen des Fischaugenbilds in eine Frontalansicht, also eine klassische Kameraansicht nach vorne, sowie eine Vogelperspektive. Diese kann durch das Fischaugenobjektiv einen großen Teil der sichtbaren Straße abdecken und für Berechnungen von anderen Modulen nutzbar machen.

4.2.2 State Machine

Die State Machine speichert den aktuellen Situationszustand des Fahrzeugs (beispielsweise `approaching_intersection` oder `default`). Damit können Module dynamisch ein-

oder ausgeschaltet werden. So kann beispielsweise das Kreuzungserkennungsmodul eingeschaltet werden, wenn die Object Detection ein Stoppschild erkennt (siehe dazu Abschnitt 4.3.4).

4.2.3 Vision

Der Softwarestack Vision beschäftigt sich mit dem Wahrnehmen der Umgebung und dem Ableiten von relevanten Informationen für die weitere Planung der Fahrt. Innerhalb des Smarty Stacks sind dies folgende Module:

1. Fahrspurerkennung
2. Objekterkennung
3. Kreuzungserkennung
4. SLAM

FAHRSPURERKENNUNG Dabei sagt die Fahrspurerkennung mit Hilfe von Machine Learning Ansätzen drei Linien auf dem Bildinput heraus, die die drei Spuren der Straße darstellen. Diese können in einem weiteren Schritt von der Pfadplanung genutzt werden, um die weitere Trajektorie des Fahrzeugs zu planen.

OBJEKTERKENNUNG Die Objekterkennung ist ein weiteres Modul des Visionstack, das Objekte in der Umgebung des Fahrzeugs mit Hilfe von ML-Ansätzen detektiert und klassifiziert. Im Kontext der CAuDri-Challenge werden durch das Objekterkennungsmodul insbesondere drei Klassen von Objekten erfasst: Verkehrsschilder, die wichtige Informationen für die Fahrtplanung und Regelkonformität liefern, also beispielsweise Fußgänger, deren Detektion essenziell für die Vermeidung von Kollisionen ist. Auch andere Fahrzeuge werden erkannt, da diese vom Egofahrzeug während der Challenge umfahren werden müsse. Die erkannten Objekte mit ihren Positionen und Klassifikationen werden anschließend an die Planungs- und Regelungsmodule weitergeleitet, um sichere und verkehrsregelkonforme Fahrmanöver zu ermöglichen.

KREUZUNGSEKENNUNG Die Kreuzungserkennung wird von dem in dieser Arbeit zu implementierenden Modul bewerkstelligt und erkennt die Position als auch die Art der Haltelinie und bestimmt aufgrund dieser Daten die Art der Kreuzung, sodass auch hier die Pfadplanung eine sichere Durchfahrt durch die Kreuzung vornehmen kann.

SIMULTANEOUS LOCALIZATION AND MAPPING Das Modul SLAM (Simultaneous Localization and Mapping) beschäftigt sich mit der Konstruktion einer internen Karte der

Strecke während sich das Fahrzeug über diese bewegt [8]. Gleichzeitig kann das Fahrzeug diese Karte nutzen, um sich dann theoretisch ohne Vision und Perzeption auf der Strecke zurechtzufinden [8]. Das SLAM Modul soll für die Disziplin Navigation verwendet werden, in welcher das Fahrzeug mehrere Objekte auf der Strecke (Landmarks) in einer zufälligen Reihenfolge abfahren muss.

4.2.4 Perzeption und Planung

Die Modulgruppe Perzeption und Planung beschäftigt sich mit folgenden Aufgabefeldern:

1. Object Tracking
2. Pfadplanung
3. Regelung

OBJECT TRACKING Die Aufgabe des Object Trackings besteht darin, Objekte, die die Objekterkennung bereits registriert hat, über mehrere Frames hinüber zu verfolgen, selbst wenn die Detektion dieser Objekte für einige Frames ausbleibt. Getrackte Objekte sind dabei Straßenschilder, Fußgänger oder andere Fahrzeuge. Die Bewegung des Fahrzeugs wird hier mit einbezogen und somit eine Vorhersage getroffen, wo sich bereits bekannte Objekte befinden könnten. Diese Informationen werden vom Fahrzeug verwendet, um auch bei Unsicherheit die richtige Trajektorie zu planen.

PFADPLANUNG Die Pfadplanung berechnet die Trajektorie, die das Fahrzeug auf der Strecke fährt. Es bezieht dabei Informationen von der Spurerkennung sowie des Object Trackings und konstruiert auf dieser Basis einen Pfad, den das Auto dabei fährt. Der Pfad selbst wird dabei nur für den Bereich geplant, den die Kamera sehen kann.

REGELUNG Die Aufgabe der Regelung ist es, dem geplanten Pfad zu folgen. Dafür muss sie bei Abweichungen der Trajektorie vom Pfad gegenregeln, um den Fehler zwischen aktueller Fahrbahn und geplanter Trajektorie zu minimieren. In einem weiteren Schritt kann auch die Längsregelung umgesetzt werden, die dann die Geschwindigkeit des Fahrzeugs regelt. Dies ist in der aktuellen Version des Fahrzeugs noch nicht umgesetzt, es fährt konstant eine fest eingestellte Geschwindigkeit.

4.2.5 Andere Module

ELEKTRONIK UND EMBEDDED Die Module Elektronik und Embedded übergreifen die Platinen auf dem Fahrzeug und die Verbindungen zwischen den Bauteilen. Sie ermöglichen somit die Kommunikation der Komponenten mit den Aktoren sowie das Steuern von Außen im Notfall und das Sammeln von Telemetrie.

SIMULATION Das Modul Simulation entwickelt Simulationsmodelle, die es erlauben, Trainingsdaten für das Training der Lane Detection und Object Detection Modelle zu trainieren.

4.3 Softwarearchitektur

Nun wird die Softwarearchitektur des Fahrzeugs beschrieben, welche die Kommunikation der Module umfasst, die in der Kreuzungsdetektion genutzten Bibliotheken und die allgemeine Struktur des Moduls. Die Fahrzeugsoftware läuft auf Ubuntu 22.04.

4.3.1 ROS2

Damit innerhalb des Fahrzeugs Ergebnisse der Module effizient und in Echtzeit ausgetauscht werden können, wird ROS2 (Robot Operating System 2) als Middleware benutzt. ROS2 erlaubt eine Abstraktion von verschiedenen Softwaremodulen. Diese werden Nodes genannt [9]. ROS2 steigt dabei im Vergleich zu ROS1 auf das DDS (Data Distribution Service) Modell um, welches Daten innerhalb des Systems in Echtzeit nach dem Publish/Subscribe Modell verteilt [10]. Somit können andere Nodes ihre Ergebnisse auf bestimmten Topics (dt. Thema) veröffentlichen und gleichzeitig auch auf anderen Topics zuhören und somit Daten empfangen.

4.3.2 Bibliotheken

Das Modul nutzt mehrere etablierte Python-Bibliotheken für die Bildverarbeitung und numerische Berechnungen:

OPENCV (OPEN SOURCE COMPUTER VISION LIBRARY) ist eine weit verbreitete Bibliothek für Echtzeit-Bildverarbeitung und Computer Vision. Sie wird in diesem Projekt für zentrale Funktionen eingesetzt: Kantenerkennung mittels Canny Edge Detection,

morphologische Operationen (Öffnen und Schließen), bilaterale und Median-Filter sowie die Perspective-Warp-Transformation für die BEV-Konvertierung. OpenCV bietet optimierte, production-ready Implementierungen dieser klassischen Bildverarbeitungsalgorithmen [11].

NUMPY wird für effiziente numerische Operationen auf mehrdimensionalen Arrays verwendet [12]. Insbesondere wird NumPy innerhalb des Moduls für Operationen zur Linienfusion und Histogrammberechnung genutzt.

SCIKIT-LEARN stellt spezialisierte Machine-Learning-Funktionen bereit [13]. Für dieses Projekt ist insbesondere der DBSCAN-Algorithmus (Density-Based Spatial Clustering of Applications with Noise) und der PCA Algorithmus relevant, die für die experimentelle Sperrflächenerkennung sowie zur Gruppierung von Liniensegmenten verwendet werden können (siehe Abschnitt 5.4.3.3 und Abschnitt 5.6.2.1).

Diese Kombination von Bibliotheken erlaubt eine effiziente Implementierung regelbasierter Bildverarbeitungsalgorithmen mit guter Rechenleistung auf embedded Hardware wie der NUC des Fahrzeugs. Diese Kombination von Bibliotheken erlaubt eine effiziente Implementierung regelbasierter Bildverarbeitungsalgorithmen mit guter Rechenleistung auf embedded Hardware wie der NUC des Fahrzeugs.

4.3.3 Struktur

Das Kreuzungserkennungsmodul folgt einer modularen Architektur mit folgenden Untermodulen:

Modul	Beschreibung
preprocessing.pipe	Bildvorverarbeitungspipeline mit Filtern und morphologischen Operationen
utils.filter	Filterfunktionen zur Selektion von Liniensegmenten nach Winkeln, Längen, ROI und optischen Eigenschaften
utils.checks	Validierungsfunktionen zur Überprüfung geometrischer Plausibilität von Linienpaaren
utils.tools	Bildverarbeitungswerkzeuge für Kantenerkennung, Eckenerkennung, Linienfusion und Gap-Detection
utils.models	Datenstrukturen und Konfigurationsmodelle für parametrisierbare Hyperparameter

aggregator	Bufferbasierter Ergebnisaggregator zur Erhöhung der Robustheit über mehrere Frames
debug_visualizer	Visualisierungsfunktionen für Zwischenergebnisse der Pipeline

Das Kreuzungserkennungsmodul folgt dabei der folgenden groben Struktur, die im Detail in erklärt wird.




Abbildung 4 – Allgemeine Pipeline des Kreuzungserkennungsmodul

4.3.4 Moduleinordnung im Gesamtsystem

Das Kreuzungserkennungsmodul arbeitet in Zusammenarbeit mit anderen Nodes. Um das Kamerabild des camera_preprocessing Nodes zu nutzen, hört das Modul auf dem Topic /camera/birds_eye. Das Debugbild des Moduls wird auf /crossing_detection/debug/image veröffentlicht und kann das zu Debugzwecken in Echtzeit analysiert werden. Das Ergebnis wird auf /crossing_detection/result veröffentlicht und wird von der State Machine des Fahrzeugs genutzt, um an der Haltelinie zum Stop zu kommen.

5

Entwicklung des Moduls

Um aus einem Rohbild aus der `camera_preprocessing` Node Informationen zu gewinnen, wird das Rohbild innerhalb einer Pipeline verarbeitet. Innerhalb der Pipeline sind mehrere Designentscheidungen zu treffen, um ein bestmögliches Ergebnis zu erzielen. Der Entwicklungsprozess wird in Iterationen durchgeführt, nach der jeder das Ergebnis der Pipeline evaluiert und getestet wird.

5.1 Bildvorverarbeitung

Das Rohbild der `camera_preprocessing` Node entspringt einer Kamera, die auf einem Gestell hinten am Fahrzeug angebracht ist. Dieses liefert ein schwarz-weiß Bild, welches dieses Modul nutzt, um Kreuzungen zu klassifizieren ().

Es stellt sich während der Entwicklung heraus, dass es von Vorteil ist, das Bild in einigen Schritten zu verarbeiten, bevor es von der Systempipeline verarbeitet wird. Die Vorverarbeitungspipeline wurde durch Testen mit Bilddaten erarbeitet, wird aber auch durch andere Umsetzungen aus der Literatur gestützt, wie bei Tsai et al. [14].

5.1.1 Bildperspektive

Bevor die allgemeine Vorverarbeitungspipeline erklärt wird, muss entschieden werden, ob für das Modul eine Frontalansicht der Kamera oder die Vogelperspektive gewählt wird, die eine perspektivische Verzerrung der Frontalansicht ist (siehe Abbildung 5). Allgemein haben sowohl die Frontalansicht, als auch die Vogelperspektive

(auch BEV für Birds Eye View) Vorteile und Nachteile, die im Folgenden aufgeführt werden. Diese gehen auch Tests während der Entwicklung hervor.

Kriterium	Frontalansicht	Vogelperspektive (BEV)
Linienerkennung	Gut - Linien sind deutlich sichtbar, vertikale Linien sind aber stets geneigt	Sehr gut - Linien sind orthogonal
Perspektivische Verzerrung	Ja - Objekte verzerrt	Nein - Orthogonale Abbildung
Schärfe	Gesamtheitlich scharfes Bild	Oberer Bereich verzerrt
Rechenaufwand	Niedrig	Höher (Transformation notwendig)
Abstand zu Objekten	Erschwert	Direkt messbar
Sichtfeld	Sehr groß, vor allem aber in Weitsicht	Geringer, aber auf Nahbereich fokussiert

Während der Entwicklung müssen nun diese Kriterien betrachtet und abgewogen werden. Für den vorliegenden Anwendungsfall sind vor allem folgende Kriterien relevant:

1. Perspektivische Verzerrung
2. Schärfe
3. Sichtfeld





Abbildung 5 — Normalansicht Kamera und Vogelperspektive (Autor)

Während der Entwicklung hat es sich als Schwierigkeit herausgestellt, dass die Frontalansicht einen weiten Blick über die Straße hat. Zwar könnte es von Vorteil sein, um die Kreuzung früher zu erkennen, aber tatsächlich ist der Großteil der Weite, die die Frontalansicht liefert, für die Kreuzungserkennung von keiner Relevanz. Negativ ins

Gewicht fällt dabei auch, dass der Kreuzungsbereich im vorderen Bildbereich stark gestaucht ist und dadurch alle Haltelinien sowie der gesamte Kreuzungsbereich in einem kleinen Bereich der ROI zusammenkommen.

Außerdem ist die perspektivische Verzerrung der Frontalansicht ein Nachteil bei der Erkennung von Haltelinien, da Linien nicht mehr orthogonal im Bild erscheinen, sondern in Richtung eines Fluchtpunktes. Das ist vor allem für Winkelberechnungen unvorteilhaft.

Ein Nachteil der Vogelperspektive ist die Unschärfe im oberen Teil des Bildes, die durch die Transformation zustandekommt. Dadurch kann es schwer sein, Linien zu erkennen, da diese stark verzerrt sind. Das ist aber durch eine Vorverarbeitungspipe-line zu beheben, weswegen für das Modul die Vogelperspektive als Bildperspektive gewählt wird.

5.1.2 Bildentzerrung

Durch die Transformation in die Vogelperspektive sind in den oberen Bereichen des Rohbildes starke Verzerrungen, sodass die Linienerkennung die gegenüberliegende Haltelinie nicht erkennen kann.

GAUSSIAN BLUR

Ein Ansatz, um Verzerrungen im Bild zu bereinigen, ist es, den gesamten Bildbereich mit einem Filter zu verarbeiten. Dafür kommt beispielsweise die Gaussche Unschärfe in Betracht, die auf Basis einer Faltung dem gesamten Bild eine Unschärfe zufügt.

Der Kernel für diese Faltung wird aufgrund folgender Vorschrift durchgeführt.

$$G(x, y) = \frac{1}{2\pi\sigma} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

Abbildung 6 — Gaussian Blur Kernelvorschrift

Aus dieser Vorschrift entsteht ein Kernel, der Pixel näher zur Mitte des Kernel stärker gewichtet als Pixel, die am Rand des Kernels liegen. Ein Beispielkernel 5x5 könnte wie folgt aussehen (siehe Abbildung 7).

$$\begin{bmatrix} 0.0037 & 0.0147 & 0.0221 & 0.0147 & 0.0037 \\ 0.0147 & 0.0586 & 0.0881 & 0.0586 & 0.0147 \\ 0.0221 & 0.0881 & 0.1325 & 0.0881 & 0.0221 \\ 0.0147 & 0.0586 & 0.0881 & 0.0586 & 0.0147 \\ 0.0037 & 0.0147 & 0.0221 & 0.0147 & 0.0037 \end{bmatrix} \quad (1)$$

Abbildung 7 – Beispiel Gaussian Kernel 5x5

Das Bild wird nun mit diesem Kernel gefaltet. Hierbei ist der Wert jedes neuen Pixels im gefilterten Bild eine gewichtete Summe aus den Nachbarpixeln (in Abbildung 7 beispielsweise 5x5 Umgebung) [15] (S. 393).

Innerhalb des Moduls kann die in OpenCV vorhandene Funktion `cv2.GaussianBlur(img, (5, 5))` verwendet werden.

Der Gauss-Filter ist nützlich, um Rauschen aus dem Bild zu entfernen und damit auch verzerrte Stellen des Bildes weicher zu machen, sodass die Linienerkennung trotz Verzerrung durch die BEV gute Ergebnisse liefert. Ein Problem des Gauss-Filters ist aber, dass er sowohl Verzerrungen, als auch bereits klare Kanten weicher macht. Das führt zu schlechteren Ergebnissen bei bereits klaren Kanten.

BILATERALER FILTER Um den Schwächen des Gauss-Filters entgegenzuwirken, wird der bilaterale Filter in Betracht gezogen. Der Vorteil des bilateralen Filters ist es, dass er Verzerrungen aufweicht, während scharfe Kanten erhalten bleiben [16] (S. 779).

Der bilaterale Filter nutzt dabei zwei Gaussche-Kernel, um den Wert des gefilterten Pixels zu berechnen. Ein Filter ist dabei ein räumlicher Filter, welcher ähnlich der Gausschen Unschärfe arbeitet. Er gewichtet nah gelegene Pixel stärker als weiter entfernte. Der Unterschied zum einfachen Gausschen-Filter ist aber, dass zusätzlich ein Intensitätskernel genutzt wird, welcher Pixel stark gewichtet, die ähnliche Intensität aufweisen und Pixel mit stark Gradienten in Intensität schwach gewichtet [16] (S. 779f).

Der bilaterale Filter weist im Vergleich zum Gauss-Filter aber höhere Rechenkosten auf, die aber mit Blick auf das Ergebnis akzeptabel sind [16] (S. 779). Deswegen wird dieser Filter in der Pipeline genutzt.

MEDIAN BLUR

Der Median-Blur arbeitet ähnlich zu den andern Filtern. Dabei wird aber kein Gauss-Kernel erzeugt, sondern alle Pixelwerte innerhalb der Kernelfläche in aufsteigender

Reihenfolge sortiert und das mittlere Element (der Median) als neuer Wert des betrachteten Pixels gesetzt. Dies macht den Filter besonders effektiv bei der Reduktion von Salz- und Pfeffer-Rauschen (engl. Salt-and-Pepper Noise), da extreme Ausreißer durch den Median-Wert ersetzt werden.

Auch der Median-Blur hat einen hohen Rechenaufwand, wird aber in Kombination mit dem bilateralen Filter genutzt, um zusätzlich Salt-and-Pepper Rauschen aus dem Bild zu entfernen. Auch dieses kann durch die Transformation in BEV erzeugt werden [17].




Abbildung 8 — Medianfilter Beispiel [17]

5.1.3 Morphologisches Öffnen und Schließen

Morphologische Operationen sind bildverarbeitende Techniken, die die Form von Objekten in Binärbildern modifizieren [18]. Sie werden in dieser Pipeline eingesetzt, um Rauschen zu reduzieren und zusammenhängende Strukturen zu verstärken.

Das morphologische Schließen (engl. Closing) ist eine Kombination aus einer Dilatation gefolgt von einer Erosion. Die Dilatation erweitert helle Regionen und füllt dabei kleine schwarze Löcher innerhalb von Objekten. Die nachfolgende Erosion reduziert die erweiterten Regionen wieder auf ihre ursprüngliche Größe. Das Ergebnis ist, dass kleine Löcher innerhalb erkannter Linien geschlossen werden, ohne die Gesamtform wesentlich zu verändern. Dies ist besonders nützlich, um unterbrochene Linienabschnitte wieder zu verbinden, die durch Rauschen oder Lichtvariationen entstanden sind [18].

Das morphologische Öffnen (engl. Opening) arbeitet gegensätzlich: Erosion gefolgt von Dilatation. Die Erosion entfernt kleine helle Objekte und verkleinert größere Objekte, während die Dilatation danach wieder vergrößert. Das Öffnen ist effektiv

zur Entfernung von Rausch-Objekten oder unerwünschten kleinen Strukturen, ohne größere Linienstrukturen zu zerstören [18].




Abbildung 9 — Morphologisches Öffnen und Schließen; (a) Originalmenge G und strukturierendes Element S ; (b) Ergebnis der Erosion von G durch S ; (c) Ergebnis der Dilation von G durch S . [17]

In der Kreuzungserkennung wird diese Kombination verwendet, um das nach der Canny-Kantenerkennung erhaltene Binärbild zu bereinigen. Das Öffnen entfernt kleine Rausch-Artefakte, während das Schließen unterbrochene Linien wieder verbindet. Dies führt zu einer robusteren Vorbereitung der Bilder für die nachfolgende Linienerkennung (siehe Abbildung 10).




Abbildung 10 — Originalbild links und Bild nach Filtern, Öffnung/Schließung und finaler Dilation (Autor)

5.1.4 Reflektionsminimierung

Durch die Einstrahlung der Sonne auf die Strecke können innerhalb des Kamerabildes Bereiche entstehen, die sehr hell sind (nah einer Intensität von 255). Diese können von der Liniendetektion falsch als Linienkandidaten klassifiziert werden. Es wird eine Methode vorgeschlagen, mit der Lichtreflektionen stark minimiert werden können (siehe Abbildung 11).

Um dem entgegenzuwirken, wird der Canny Algorithmus mit dem LSD (siehe Abschnitt 5.2 ff.), um Linienkandidaten zu gewinnen. Diese werden dann gefiltert und fusioniert (siehe Abschnitt 5.3.3 und Abschnitt 5.4.5). Nun gibt es eine Menge L an Linienkandidaten, die in ihrer Allgemeinheit zufriedenstellend für eine Detektion wären, aber durch Reflektionen im Bild auch zu falschen Detektionen führen könnten.

Die Koordinaten der Elemente aus L werden nun zu Pixelindizes umgerechnet, um eine Pixelmaske zu erhalten, welche zur Analyse von Intensitätswerten genutzt werden kann. Es wird nun über die relevanten Pixel in der Maske iteriert und diese zu einer Liste hinzugefügt. Daraufhin wird das 90. Perzentil dieser Liste an Intensitätswerten als Fixpunkt p angenommen. Nun werden analog zu Abschnitt 5.7.2 alle Pixel Sigmoidbasiert um diesen Threshold normalisiert. Stark hellere als auch stark dunklere Pixel werden stark verdunkelt und Pixelwerte, die in der Nähe von p sind, werden verstärkt. Es ergibt sich ein optimiertes Bild, in dem Reflektionen unterdrückt und tatsächliche Linien verstärkt werden.




Abbildung 11 — (a) Bild aus Abbildung 10, (b) LSD Linien (fusioniert), (c) Helligkeitsangepasstes Bild

5.1.5 Kontrastoptimierung mit CLAHE

Nachdem Reflektionen im Bild minimiert wurden, liegt ein Bild vor, welches gegenüber dem Rohbild zu signifikant geringeren Falschdetektionen führt. Nun soll zusätzlich sichergestellt werden, dass der Kontrast des Bildes jederzeit normalisiert ist. Das ist wichtig, da Weißwertberechnungen (siehe Abschnitt 5.7.2) in einem regelbasierten

Detektionssystem nach festen Schwellenwerten arbeiten, die nicht zwischen Frames stark schwanken sollen.

Zu diesem Zweck wird eine CLAHE-Transformation (Contrast Limited Adaptive Histogram Equalization) angewendet. CLAHE ist eine lokale Kontrasterhöhungsmethode, die das Bild in kleinere Kacheln unterteilt und die Histogrammausgleichung auf jede Kachel einzeln anwendet. Der `clipLimit`-Parameter (hier 2.0) begrenzt die Kontrasterhöhung, um eine Überamplifizierung von Rauschen zu vermeiden. CLAHE ist robuster als globale Kontrasterhöhung, da sie lokale Lichtvariationen korrekt ausgleicht. Dies führt dazu, dass die Bildvorverarbeitung auch unter variierenden Lichtverhältnissen konsistente Ergebnisse liefert [19].



Abbildung 12 — (a) Inputbild, (b) Bild aus Abbildung 11, (c) CLAHE-optimiertes Bild

5.2 Kantenerkennung

Ziel des ersten Entwicklungssinkrements ist das Extrahieren von Linien aus dem Rohbild. Dafür werden verschiedene Methodiken betrachtet, mit denen aus dem Rohbild eine Menge an Linien extrahiert werden kann, die dann in weiteren Schritten zum Bestimmen der Ego- und Opp-Haltelinien genutzt werden können.

5.2.1 Canny Edge Detector

Bevor Linien aus dem Rohbild extrahiert werden können, muss dieses erstmal vorverarbeitet werden. Der erste Verarbeitungsschritt ist es, aus dem Rohbild Kanten zu detektieren. Kantendetektion ist ein Verfahren, bei dem versucht wird, die Kanten von Flächen innerhalb eines Bildes zu detektieren, indem Stellen innerhalb des Bildes ermittelt werden, an denen die Intensitätsänderung der Pixelhelligkeiten besonders stark ist [20] [S.53].

Der Canny Edge Detection Algorithmus besteht aus mehreren Schritten. Das Rohbild ist dabei ein Graustufenbild und nicht farbig.

1. Im ersten Schritt wird das Bild entrauscht. Dafür wird der Gaussian Blur (dt. Gaußscher Weichzeichner) auf das gesamte Bild angewandt. Dieser wird nach folgender Vorschrift durchgeführt $G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$.
2. Nun das Bild mit zwei Matrizen G_x und G_y , den so genannten Sobel-Filtern gefaltet. Diese sind wie folgt definiert.

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \quad (2) \quad G_y = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix} \quad (3)$$

Die Faltung mit diesen zwei Matrizen resultiert in einem neuen Bild, welches an den Stellen, an denen der Gradient der Pixelwerte zwischen benachbarten Pixeln am größten ist, hellere Pixel hat als an Stellen, wo der Gradient nicht so stark ist. Benachbarte Pixel, die alle den selben Wert haben, werden nach der Faltung einen Pixelwert von 0 haben, weswegen sie schwarz sind. Da sowohl entlang der x-Achse als auch der y-Achse gefaltet wird, wird jedem Pixel somit ein Vektor der Größe 2×1 , welcher die Intensität der Änderung in der respektiven Richtung anzeigt.

3. Die Werte aus dem Spaltenvektor mit den Intensitätswerten des Gradienten werden nun benutzt, um die Richtung der Kante zu bestimmen. Die Richtung der Änderung wird mit $\theta = \arctan\left(\frac{G_y}{G_x}\right)$ berechnet. Es kann vorkommen, dass G_x den Wert Null besitzt. In diesem Fall wird der Winkel als 90 Grad angesetzt.
4. Nun wird auf die gesamte Intensitätsmatrix nach der Schritt 3 die Non-Maximum Suppression durchgeführt. Diese betrachtet nun in Richtung der maximalen Änderung (Schritt 3) die Intensitätswerte aus der Gradientenmatrix aus Schritt 2. Dabei wird entlang dieser Richtung das lokale Maximum erhalten und die restlichen Pixelwerte auf 0 gesetzt. Somit wird hier eine klare Kante errechnet (siehe Gleichung 4).

$$\text{NMS}(x, y) = \begin{cases} M(x, y) & \text{falls } M(x, y) \geq M(g_1) \text{ und } M(x, y) \geq M(g_2) \\ 0 & \text{sonst} \end{cases} \quad (4)$$

5. Nun werden zwei Schwellenwerte t_{high} und t_{low} festgelegt. Anhand dieser Schwellenwerte werden Pixel in drei Kategorien unterteilt:
 - Keine Kante
 - Schwache Kante
 - Starke Kante

Canny klassifiziert schwache Kanten nur als Kante, wenn sie mit einem Pixel verbunden sind, der als starke Kante klassifiziert wurde oder über eine Kette schwacher Pixel eine Verbindung vorliegt. Pixel mit Wert unterhalb des Schwellenwerts

werden ausgefiltert [21] [S.127ff]. So entsteht ein Bild, welches mit hellen Pixeln die Kanten des Rohbildes darstellt (siehe Abbildung 14).




Abbildung 14 — Ergebnis Canny-Edge Detektion (Autor)

5.3 Linienextraktion

Das gewonnene Bild wird nun zur Linienextraktion verwendet.

Allgemein werden zwei Verfahren für die Detektion von Liniensegmenten geprüft, welche oft in der digitalen Bildverarbeitung Verwendung finden. Diese sind zum einen die Hough Transformation und der Line Segment Detector (LSD) Algorithmus nach Rafael Grompone von Gioi et al.

5.3.1 Line Segment Detector

Der LSD Algorithmus ist ein geometrischer Extraktionsalgorithmus, welcher in linearer Zeit subpixel genaue Ergebnisse zu Liniensegmenten liefern kann. Auch der LSD basiert auf der Detektion von sich lokal stark ändernden Pixelwerten. Der LSD erstellt ein Vektorfeld, dessen Vektoren orthogonal zu den Richtungsvektoren der Gradientenänderung stehen (siehe Abbildung 13). Dies sieht dann wie folgt aus.




Abbildung 15 – LSD Vektorfeld

[22] Aus diesen Vektoren werden so genannte line support regions generiert die in Abbildung 15. Diese Regionen sind potentielle Linien. Um diese line support regions Wird ein Rechteck gelegt, dessen Ausrichtung entlang der Ausrichtung der Vektoren in diesem Feld liegt.

Nun wird jedes Rechteck durch das Helmholtz-Prinzip und der a contrario-Methode validiert. Nach dieser Methode wird ein Modell erstellt, welches in seiner Gesamtheit aus Rauschen besteht. Es wird nun angenommen, dass das Rechteck in solch einer Struktur nicht wiedergefunden werden kann. Das Rechteck wird validiert, wenn auf diesem Rausch-Modell nur eine sehr geringe Anzahl bis gar keine Ereignisse des selben Rechtecks auftreten [22] (S. 36f).

Ein großer Vorteil des LSD ist, dass er vollständig ohne das Anpassen von Parametern funktioniert und Parameter innerhalb des Algorithmus gar nicht geändert werden können.

5.3.2 Hough Transformation

Auch die Hough-Transformation ist ein Algorithmus, welcher zur Detektion von Linien genutzt wird.

Innerhalb eines Bildes können alle geraden Linien als eine zwei-Parameter Familie gesehen werden. Folglich wird jede Linie mit zwei Parametern θ und ρ beschrieben. Es wäre naheliegend, eine Linie in der Form $y = m * x + b$ darzustellen. Diese Darstellung scheitert aber daran, dass vertikale Linien mit einer unendlichen Steigung beschrieben werden würden, was digitale Berechnungen kompliziert macht.

HOUGH RAUM Die einfache Darstellung einer Linie im Folgenden trotzdem genutzt, um den Hough Raum zu erklären. Man stelle sich eine Menge M_P an Punkten vor, die

innerhalb eines Bilds auf einer Linie liegen. Diese Linie kann mit der oben beschriebenen Formel für eine Linie innerhalb des Bilds beschrieben werden. Dabei sind x_i und y_i beliebige Punkte auf der Linie, die aber vorerst unbekannt sind. Nun wird die Beschreibung der Linie zu $b = -m * x + y$ umgestellt. Nimmt man nun einen Punkt aus M_P und setzt ihn in die genannte Formel ein, erhält man eine Linie im Parameterraum (siehe Abbildung 16).

Diese Linie beschreibt nun alle Linien im Bildbereich, die diesen Punkt kreuzen. Dies wird nun für alle Punkte der Menge durchgeführt. Es ergibt sich ein Punkt (m, b) , welcher die gesuchte Linie im Bildraum darstellt, auf der alle Punkte der Menge M_P liegen. Nimmt man nun einen Punkt, der nicht auf der gesuchten Linie liegt, erhält man eine Linie im Parameterraum, die keinen gemeinsamen Schnittpunkt mit den anderen gefundenen Linien besitzt.





Abbildung 16 – Bild- und Parameterraum https://www.youtube.com/watch?v=XRBC_xkZREg

LINIENBESTIMMUNG Um nun innerhalb eines Bildes Linien zu erkennen, wird der jüngst beschriebene Hough-Raum verwendet. Dafür wird der Parameterraum P quantisiert. Dafür wird eine Matrix $A(m, b)$ über dem Parameterraum erstellt, die auch Akkumulator-Array genannt wird. Zu Beginn des Algorithmus wird dieses Array mit Nullen besetzt und sieht folglich so aus:



Nun hat ein Kantenerkennungsalgorithmus Punkte innerhalb des Bildes erkannt, die potenzielle Linien sein könnten. Diese sind eine Menge K . Aus Effizienzgründen werden nicht die klassischen Geradenparameter m und b verwendet, sondern die Normalform mit den Parametern ρ (Abstand) und θ (Winkel).

Die Normalform einer Linie wird durch folgende Formel definiert:

$$\rho = x * \cos(\theta) + y * \sin(\theta)$$

Abbildung 17 – Normalform einer Geraden im Hough-Raum

Dabei ist:

- ρ der senkrechte Abstand von der Linie zum Ursprung (Betrag zwischen 0 und der Bilddiagonale)
- θ der Winkel des Normalenvektors der Linie zur x-Achse (typischerweise 0° bis 180°)

Der Vorteil dieser Parametrisierung ist, dass sie die gesamte Bildebene abdeckt und Singularitäten bei vertikalen Linien vermeidet, die bei der Steigungsform $m = \infty$ auftreten würde.

Ablauf des Hough-Transform-Algorithmus:

Für jeden erkannten Kantenpunkt (x_i, y_i) aus K werden alle möglichen Linien berechnet, die durch diesen Punkt verlaufen. Dies geschieht durch die Diskretisierung des θ -Bereichs in Schritte θ_j und das Berechnen der entsprechenden ρ -Werte nach obiger Formel. Im Akkumulator-Array (siehe oberes Diagramm) wird für jede berechnete Parameterkombination (ρ, θ) ein Zähler erhöht - ein Punkt „stimmt“ für die Parameter.

Nach der Verarbeitung aller Kantenpunkte enthält der Akkumulator Maxima an den Parameterkombinationen, die vielen Kantenpunkten entsprechen. Das untere Diagramm zeigt ein Beispiel mit 3 kollinearen Kantenpunkten: diese erzeugen Votes in vertikaler, horizontaler und diagonaler Richtung, die sich in der Mitte treffen und ein Maximum mit 3 Stimmen bilden. Diese Maxima repräsentieren die tatsächlich im Bild vorhandenen Linien.

Das gefüllte Akkumulator-Array nach der Verarbeitung könnte beispielsweise wie folgt aussehen:

0	0	1	0	1
0	0	1	1	0
1	1	3	1	1
0	1	1	0	0
1	0	1	0	0

Die rot markierte Zelle mit dem Wert 3 zeigt das Maximum im Akkumulator-Array, das von drei kollinearen Kantenpunkten erzeugt wird. Diese drei Votes entstehen durch die vertikale, horizontale und diagonale Ausrichtung der Kantenpunkte. Das detektierte Maximum (ρ_0, θ_0) wird als Parameterpaar für eine erkannte Linie verwendet. Nach der Verarbeitung aller Kantenpunkte können weitere Maxima ermittelt und damit mehrere Linien im Bild lokalisiert werden [23].

5.3.3 Pipeline für die Linienerkennung

Es wurden nun zwei Algorithmen zur Erkennung von Linien in einem Bild vorgestellt.

Durch praktische Tests hat sich der LSD Algorithmus dabei als die optimale Lösung für die Kreuzungserkennung erweisen, da dieser Algorithmus ohne weiteres Tuning von Parametern sehr zufriedenstellend funktioniert. Außerdem ist zu nennen, dass der LSD mit einer Zeitkomplexität von $O(n)$ deutlich effizienter funktioniert, als die Hough Transformation [24] (S.27). Somit wird für die Liniendetektion der Kreuzungserkennung der Canny Algorithmus mit nachgeschaltetem LSD Algorithmus gewählt.




Abbildung 18 — Pipeline für Linienerkennung

5.4 Linienvorverarbeitung

5.4.1 Linienlängenfilter

Nachdem das Modul nun Linien aus einem Rohbild erkennen kann, sind noch einige Schritte nötig, um das Ergebnis der Linienerkennung besser nutzbar zu machen. Zum

Einen ist es wichtig, zu kurze Linien aus der Menge der gefundenen Linien herauszufiltern. Das ist wichtig, da Haltelinien nach der Erkennung immer eine bestimmte Länge haben.

Eine Linie L sei innerhalb des Moduls als ein Vektor aus vier Werten dargestellt. Dieser Vektor L sei beschrieben durch $L = (x_1, y_1, x_2, y_2)$. Die Koordinaten innerhalb des Vektors stellen die Anfangs- und Endpunkte der Linie dar. Somit kann die Länge der Linie durch die euklidische Distanzformel $\text{length} = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$ berechnet werden. Es ergibt sich folgender Code.

python

```
1 def filter_by_length(self, lines, min_l: float = 70.0, max_l=10000):
2     res = []
3     for line in lines:
4         x1, y1, x2, y2 = line[0]
5         length = math.sqrt((x2 - x1) ** 2 + (y2 - y1) ** 2)
6         if length >= min_l and length <= max_l:
7             res.append(line)
8     return res
```

Euklidische Distanzformel zur Berechnung der Linienlänge

Abbildung 19 — Längenfiltration erkannter Linien

Es werden nur Linien mit einer Länge zwischen `min_l` und `max_l` behalten. Dies ist wichtig, um Rauschlinien auszuschließen und nur relevante Strukturen zu verarbeiten.

TODO: anfügen irgendwo, dass Variablennamen gekürzt werden aus Lesbarkeitsgründen

Durch Tests auf Sicht hat sich für einen ersten Längenfilter der Linien eine Pixellänge von 20 bewährt. Damit werden vorerst kleine Rauschlinien aus der potentiellen Menge entfernt.

Filterung der Linien ist wichtig, da eine geringe Menge an Linien dazu führt, dass das später zu implementierende System weniger Möglichkeiten hat, eine falsche Linie auszuwählen.

TODO: bild

5.4.2 Region of Interest Filter

Der Region-of-Interest-Filter (ROI-Filter) beschränkt die verarbeiteten Linien auf einen definierten Bereich des Bildes. Dies ist besonders hilfreich, um irrelevante Bildbereiche auszuschließen und die Verarbeitung auf die Bereiche zu konzentrieren, in denen tatsächlich relevante Kreuzungen zu erwarten sind. Der ROI wird durch relative prozentuale Grenzen definiert, die automatisch auf die tatsächliche Bildgröße skaliert werden.

Das Konzept des ROI-Filters lässt sich algorithmisch wie folgt darstellen:

Algorithmus 1: ROI-basierte Linienfilterung

Eingabe: Liste von Linien, Bildhöhe und -breite, ROI-Grenzen (in %)

Ausgabe: Gefilterte Liste von Linien

1. Konvertiere relative ROI-Grenzen in absolute Pixelkoordinaten
2. Für jede Linie: Behalte sie nur, wenn beide Endpunkte in der ROI liegen
3. Gib die gefilterten Linien zurück

Für die relativen ROI-Grenzen wird durch Tests eine Definition von `FILTERING_ROI_REL_RLTB = (0.80, 0, 0, 0.815)` gewählt.

5.4.3 Linienfusion

Nachdem Linien nach Ort und Länge gefiltert wurden, ist beim Testen ein Problem zu beobachten. Durch Sichttests wird festgestellt, dass in vielen Fällen tatsächliche Haltelinien durch mehrere, unterbrochene Linien dargestellt werden, die logisch zu einer Linie im Bild gehören. Außerdem sind die zu erkennenden Linien stets gerade, es werden also keine Kurven erkannt. Deswegen ist es ein sinnvoller Schritt, die gefunden Linien zu fusionieren. Die Idee ist, Linien, die örtlich nebeneinander liegen und ähnliche Winkel haben, zu einer Linie zu fusionieren. Ziel ist es also, aus einer Menge an Linien eine einzelne repräsentative Linie zu finden (siehe Abbildung 20).

Die Fusion der Linien läuft wie folgt ab:

Algorithmus 2: Linienfusion durch Greedy Clustering

Eingabe: Liste von Linien, Winkeltoleranz, Distanztoleranz

Ausgabe: Liste der fusionierten Linien

1. Berechne Winkel und Mittelpunkt jeder Linie
2. Gruppiere Linien mit ähnlichem Winkel und nah beieinander liegendem Mittelpunkt (Greedy Clustering)
3. Für jede Gruppe: Sammle alle Endpunkte, nutze PCA zur Hauptachsen-Berechnung
4. Projiziere Endpunkte auf die Hauptachse und finde die Extrempunkte
5. Diese Extrempunkte werden die Endpunkte der fusionierten Linie
6. Gib die Liste der fusionierten Linien zurück

Im Folgenden werden die Schritte des Algorithmus näher erläutert.

WINKEL- UND MITTELPUNKTSBERECHNUNG Um die Winkel und Mittelpunkte der Linien zu berechnen, wird eine Linie zuerst als Vektor dargestellt. Durch Differenzbildung zwischen den Start- und Endpunkten erhalten wir einen Linienvektor. Dieser sieht wie folgt aus: $l = \begin{pmatrix} x_2 - x_1 \\ y_2 - y_1 \end{pmatrix}$. Nun wird aus diesem Vektor mit `math.atan2(dy, dx)` der Winkel der Linie bestimmt. Der Mittelpunkt wird durch Division des Vektors mit Zwei bestimmt.

GRUPPIERUNG DER LINIEN Nun wird über alle Linien iteriert. Bei jeder Iteration i wird nun geprüft, ob diese Linie bereits überprüft wurde. Ist dies nicht der Fall, wird in einer weiteren Schleife im Bereich $[i + 1, n]$ der Differenzwinkel und die Differenzdistanz des Elements j zum Element i berechnet. Liegen diese Werte innerhalb eines vorgegebenen Toleranzbereichs, werden sie in eine Gruppe mit dem Element i hinzugefügt. Es bilden sich somit Gruppen aus Linien mit ähnlicher Ausrichtung, die nah beieinander liegen. Gruppen mit zu wenigen Mitgliedern werden gelöscht.

PRINCIPAL COMPONENT ANALYSIS Für jede Linie werden die Start- und Endpunkte bestimmt. Die zuvor bestimmten Gruppen werden somit also zu 2D-Punktemengen. Nun wird die Principal Component Analysis (PCA) verwendet, um die Gerade zu finden, die am besten durch die gesamte Punktwolke passt.

Um die PCA durchzuführen, müssen die Punkte vorverarbeitet werden. Zum Einen wird der Mittelpunkt aller Punkte bestimmt und anschließend jeder Punkt um diesen Mittelwert verschoben. Das hat zur Folge, dass der Mittelwert aller Punkte nun im Ursprung liegt [25] (S. 433). Nun wird die Single Value Decomposition (SVD) genutzt, um die Punktwolke in Hauptachsen zu zerlegen. Im Code wird dies mit folgendem

Befehl durchgeführt: $U, S, Vt = \text{np.linalg.svd}(pts - \text{mean})$. Vt liefert nun eine Matrix mit den Hauptachsen der Punktwolke. Darin ist der erste Vektor $Vt[0]$ die Hauptachse der Datenpunkte, also die Achse „in der sich die Punkte am weitesten ausbreiten“. Die zweite Achse liegt dann orthogonal auf der Hauptachse [25] (S. 434ff). Es wird die erste Hauptachse genutzt, um die „Richtung“ der Punktwolke zu finden, die dann zum konstruieren der fusionierten Linie benutzt werden kann. die Punkte aus der Punktwolke werden jetzt entlang der Hauptachse projiziert und anschließend die Extrema P_1 und P_2 der Projektion gespeichert. Diese werden nun mit der Formel $p = \text{mean} + m * s$ also $P_{2d_max} = \text{mean} + m * P_1$ und $P_{2d_min} = \text{mean} + m * P_2$ zurück in den 2D-Raum gerechnet. Das sind dann die Punkte der fusionierten Linie. Diese fusionierte Linie wird nun einem Ergebnisarray angehängen.




Abbildung 20 — (a) Rohe Linienoutput aus LSD, (b) gefiltert und fusioniert

5.4.4 Winkelfilter

Um einen weiteren Filter zu konzipieren, der die Menge an Linien, die zur Detektion von Haltelinien in Betracht fallen, minimiert, muss die Hauptausrichtung aller Haltelinien beachtet werden. Diese sind relativ zum Fahrzeug in erster Linie stets vertikal oder horizontal. Somit ist es sinnvoll, einen Filter zu implementieren, der Linien anhand ihres Winkels ausschließen kann.

Der Winkelfilter iteriert über eine Menge an Linien und berechnet durch den Winkel des Differenzvektors des Start- und Endpunkts der Linie die Ausrichtung eben dieser. Dieser Winkel wird nun normalisiert und daraufhin getestet, ob dieser innerhalb einer Toleranz um 90 Grad bzw. 0 Grad liegt. Die Linien werden als zwei Listen `horiz` und `vert` zurückgegeben.

5.4.5 Pipeline für die Linienvorverarbeitung

Die Linienvorverarbeitung folgt einer festen Pipeline mit vier Filterschritten. Diese werden nacheinander auf die erkannten Linien angewendet, um die Menge an irrelevanten oder fehlerhaften Linien zu reduzieren:




Abbildung 21 — Pipeline für Linienvorverarbeitung und Filterung

Durch Testen dieser Pipeline haben sich außerdem einige Verbesserungsmöglichkeiten ergeben, die auch in die Pipeline integriert werden. So ist zu beobachten, dass durch Wiederholung der Fusionsschritte, zuerst mit einer höheren Winkeltoleranz (15 Grad) und Abstandstoleranz (100 Pixel) und danach mit einer geringen Winkeltoleranz (5 Grad) und höherer Abstandstoleranz (120 Pixel) repräsentativere Linien erzeugt werden können.

Es wurde auch das dreifache Fusionieren getestet, welches aber im Vergleich zu der zusätzlichen Laufzeit keine Verbesserungen, sondern eher Verschlechterungen zur Linienqualität gebracht hat.

5.5 Haltelinienklassifikation

Nach der Linienvorverarbeitung liegt nun eine Menge an Linien vor, die für die korrekte Detektion der Haltelinien in Frage kommen. Zuerst wird festgelegt, welche Haltelinien gesucht werden. Diese sind:

1. Haltelinie der eigenen Fahrspur (Egolinie)
2. Haltelinie der gegenüberliegenden Fahrspur (Opp-Linie für opposing lane)
3. Rechte Haltelinie
4. Linke Haltelinie

Es muss auch die Position und die Art der Linie bestimmt werden. Jede Linienart kann sowohl als durchgezogene Linie, als auch als gestrichelte Linie vorliegen.

5.5.1 Primitive Ermittlung der Ego- und Opplinie

In einem ersten Schritt liegt es nah, die Haltelinie der eigenen Spur zu detektieren. Diese erlaubt es dem Fahrzeug während der Caudri-Challenge rechtmäßig zum Halt zu kommen und gegebenenfalls andere Linien zu detektieren.

Als erster Ansatz wird die Methode gewählt, die Linie als Ego- oder Opplinie zu klassifizieren, die in ihrer Position am nächsten zum Fahrzeug ist und eine horizontale Ausrichtung hat. Um dies umzusetzen, wird der bereits implementierte Winkelfilter genutzt. Durch diesen erhalten wir eine Menge an Linien *horiz*, die alle horizontalen Linien in der Region of Interest darstellen. Nun wird über alle in dieser Menge enthaltenen Linien iteriert und diese dabei nach der Entfernung zur Mitte der untersten ROI Kante sortiert. Die Linie, die den geringsten Abstand aufweist, ist die Ego- oder Opplinie. Nach einer analogen Logik wird nun auch die Opplinie ermittelt, in dem nach der Linie mit geringstem Abstand zur oberen ROI Kante gesucht wird (siehe Abbildung 22).




Abbildung 22 — Primitive Ego- und Opp-Entfernung links, Ego- und Opp-Entfernung rechts (Autor)

Diese vorgestellte Methode liefert zufriedenstellende Ergebnisse in Kreuzungen, in denen nur eine Ego- und Opplinie vorhanden sind. Außerdem sollten die Lichtverhältnisse so ausgelegt sein, dass der LSD keine weiteren Linien erkennt, die um die Ego- oder Opplinie herumliegen. Ist dies der Fall, werden Linien falsch klassifiziert. Neben der genannten Schwäche nutzt diese Methodik nicht die allgemeine Struktur einer Kreuzung aus. Innerhalb dieser liegen alle Haltelinien in einem bestimmten, leicht variablen Abstand von einander innerhalb der Kreuzung. Die Kreuzung selbst kann als ein Quadrat interpretiert werden, welches entweder eine Kante (Haltelinie) oder keine Kante besitzen kann. Die Richtung, in der Spuren in die Kreuzung hineinfließen, ist mit Ausnahme der eigenen Spur, für die Kreuzungsklassifikation nicht relevant.

Mit Blick auf diese Erkenntnisse wird eine neue Methodik entwickelt, die es erlaubt, zuverlässiger die Ego- und Opplinie zu erkennen.

5.5.2 Kreuzungsmittenbasierte Detektion

Die Struktur einer Kreuzung legt nahe, dass Haltelinien stets relativ zueinander in einer ähnlichen Position liegen, die in Abschnitt 5.5.1 beschrieben ist. Auf Basis dieser Idee wird nun die Kreuzungsmitte genutzt, um Haltelinien zu detektieren.

In einem ersten Versuch, die Kreuzungsmitte zur Detektion der Haltelinien zu nutzen, wird anstatt der Kanten der ROI nun die Kreuzungsmitte als Anhaltspunkt für Abstandsberechnungen genutzt. Demnach sind die Linien Ego- und Opplinie, die am nächsten zur Kreuzungsmitte liegen.

Diese Methodik weist gegenüber der primitiven Methodik einige wichtige Verbesserungen auf. Die wichtigste Verbesserung ist, dass die Erkennung nun nicht darauf gestützt ist, dass der Bildausschnitt genau so auf der Kreuzung liegt, dass Ego- und Opplinie die nächsten Linien zur ROI Unter- bzw. Oberkante sind. Das ist vor allem der Fall, wenn das Fahrzeug noch weiter von der Kreuzung entfernt ist oder der LSD eine Linie erkennt, die zwischen einer der ROI Kanten und der tatsächlichen Kreuzung liegt. Durch diese Methodik wird nun auch die Struktur einer Kreuzung ausgenutzt, in der Haltelinien relativ zueinander immer gleich angeordnet sind. Dies erzeugt eine robustere Halteliniendetektion. Die Implementierung der Kreuzungsmittenberechnung ist in Abschnitt 5.6 beschrieben.

5.5.3 Sektorbasierte Detektion der rechten und linken Haltelinie

Nachdem nun vorerst die Ego- und die Opplinie erkannt werden, ist es wichtig, auch die Haltelinien der Spur, die von Egoausrichtung rechts in die Kreuzung einmündet und die Haltelinie der Spur links zu detektieren. Die Idee der Kreuzungsmitte legt nahe, dass diese auch zur Detektion der rechten und linken Haltelinie genutzt werden kann. Man berechne die vertikalen Linien, die am nächsten am Kreuzungszentrum sind. In der Entwicklung ist man nun aber mit der Schwierigkeit konfrontiert, dass die Kreuzungsmitte nicht zuverlässig perfekt zentral platziert ist. Dies hat zur Folge, dass oft Linien, die tatsächlich zur Spur gehören, als Haltelinien erkannt werden.

DREIECKSSEKTOR Aufgrund dieser Tatsache wird eine Methodik vorgestellt, die zwei dreieckige Sektoren nutzt, die innerhalb der ROI rechts und links platziert werden, um entsprechende Haltelinien zu finden. Diese Sektoren bestehen aus einem nach oben geöffneten Dreieck für die rechte Haltelinie und einem nach unten geöffneten Dreieck für die linke Haltelinie. Die Dreiecksstruktur ist darin begründet, dass bei minimalem Lenken des Fahrzeugs die Querhaltelinien in x-Position teilweise nach rechts oder links verschoben sein können.

Innerhalb des Sektors wird nun die Linie als Haltelinie ausgewählt, die am längsten ist.

Ein Problem dieser Sektorform ist, dass die Fläche, in der die Haltelinie gesucht wird, zur Grundseite des Dreiecks am größten ist. Das bewirkt, dass die Suchfläche (beispielsweise für die rechte Haltelinie) größer ist, je weiter die Kreuzung vom Fahr-

zeug entfernt ist. Das führt dazu, dass die tatsächliche Haltelinie nicht innerhalb der Suchregion liegt, wenn das Fahrzeug an der Kreuzung steht.

TRAPEZFÖRMIGER SEKTOR Um dem Umstand entgegenzuwirken, dass die Querhaltelinien nicht in der Suchregion liegen, wird der Sektor zu einer Trapezform geändert. Diese werden auf der rechten und linken Seite der ROI platziert. Diese Änderung hat zur Folge, dass der Suchbereich in der Mitte der Höhe der ROI am größten ist. Steht das Fahrzeug nun vor der Kreuzung, soll die Haltelinie theoretisch innerhalb des Sektors liegen.




Abbildung 23 — Trapezförmige Sektoren für linke und rechte Haltelinien (Autor)

Nach weiteren Überlegungen und Tests wird auch dieser Ansatz verworfen, da statische Formen innerhalb der ROI, in denen die Haltelinien theoretisch zu erwarten sind, nicht zuverlässig funktionieren. Je nach Kalibrierung der Kamera und Anfahrt auf die Kreuzung, müssten sich die Sektoren in ihrer Position verändern.

QUADRANTENBASIERTE SUCHE Die ROI wird nun in vier Quadranten unterteilt, die von Q1 bis Q4 (1 - oben links, 2 - oben rechts, 3 - unten links, 4 - unten rechts) nummeriert sind. Innerhalb dieser Quadranten wird nun die rechte Haltelinie im Quadranten zwei oder im Quadranten 4 erwartet. Die linke Haltelinie wird im Quadranten eins erwartet. Der Quadrant drei wird für die linke Haltelinie nicht in Betracht gezogen, da durch die Kameraperspektive in diesen Quadranten keine nutzbaren Informationen (also kein nutzbares Bild) abgebildet sind.

Mit Hilfe der Quadrantenbasierten Suche gelingt es, Querhaltelinien zu erkennen.

TODO: wie und wann Sprung auf BEV erklären

5.5.4 Zentrumsbasierte Detektion aller Haltelinien

Die vorgestellten Methoden zur Detektion der rechten und linken Haltelinien weisen bei Kreuzungsanfahrt aus Kurven oder bei falsch detektierten Linien enorme Defizite auf.

Aufgrund dieses Umstands werden auch die Querhaltelinien auf Basis des Kreuzungszentrums berechnet. Es bleibt jedoch die Schwierigkeit, dass die aus dem Bilddaten berechnete Position des Kreuzungszentrums nicht exakt mit der tatsächlichen Position des Kreuzungszentrums übereinstimmt. Um diesem Problem entgegenzuwirken, werden die aus dem Kreuzungszentrum abgeleiteten Referenzpunkte (siehe auch Abschnitt 5.6.5) genutzt. Mit Hilfe dieser Referenzpunkte ist es möglich, eine zuverlässige Detektion aller Haltelinien aus der Menge der vorverarbeiteten Linien durchzuführen.

Es wird auch die Hauptspurausrichtung genutzt, um die Referenzpunkte so zu berechnen, dass die Referenzen für die Ego- und Opplinie in Richtung des Spurwinkels liegen und die Referenzpunkte für die rechte und linke Haltelinie orthogonal dazu liegen (siehe dazu Abschnitt 5.6.5).

5.6 Berechnung des Kreuzungszentrums

Die Struktur der Kreuzungen innerhalb der Caudri-Challenge können zur verbesserten Detektion von Haltelinien ausgenutzt werden. Demnach liegen die Haltelinien jeder Kreuzung stets auf den Kanten eines Quadrats, dessen Ecken die Punkte sind, an denen die Spuren zur Kreuzung zusammenkommen.

5.6.1 Primitive Bestimmung der Kreuzungsmitte

Als erster Schritt liegt es nah, die Kreuzungsmitte als Zentrum der ROI festzulegen. Dies ist tatsächlich hilfreich, da es ein erster Schritt ist, die Struktur der Kreuzung auszunutzen und nicht Abstandsberechnung zu den Kanten der ROI zu nutzen. Allerdings weist diese Methodik das Problem auf, dass die Korrekten Haltelinien nur richtig erkannt werden, wenn das ROI-Zentrum gerade innerhalb der tatsächlichen Kreuzung liegt. Ist das Fahrzeug noch weiter von der Kreuzung entfernt oder ist schon zu Teilen in die Kreuzung hineingefahren, kann es dazu kommen, dass Linien außerhalb der Kreuzung als Haltelinien klassifiziert werden.

5.6.2 Algorithmische Kreuzungsmittendetektion

Bei weiterer Überlegung, die tatsächliche Kreuzungsmitte zu berechnen, wird ersichtlich, dass mehr Bildinformationen genutzt werden können, um das Zentrum verlässlicher zu berechnen.

Es ist denkbar, die Schnittpunkte der Spurlinien zu berechnen und daraufhin daraus das Kreuzungszentrum abzuleiten. Da bisher kein Ansatz ausgearbeitet wurde, um die Spuren aus dem Kamerabild zu berechnen, muss zuerst festgelegt werden, welche der Linien aus der gesamten Linienmenge potentielle Spuren sind.

DBSCAN Ein Ansatz, um Spurlinien zu erkennen und daraufhin die Kreuzungsmitte zu berechnen, ist der DBSCAN Algorithmus.

Der Algorithmus beruht auf der Idee, aus einem mehrdimensionalen Datensatz so genannte Cluster (dt. Haufen) an Datenpunkten zu finden, wobei die clusterinterne Ähnlichkeit maximiert und die Ähnlichkeit zwischen den Clustern minimiert werden soll [26] (S. 232). Ein Clustering Algorithmus wird dann als effektiv angesehen, wenn er viele der folgenden Kriterien abdeckt [26] (S. 232):

- Der Entwickler braucht minimale Domänenkenntnisse, um den Algorithmus zufriedenstellend zu parametrieren
- Der Algorithmus erkennt Cluster beliebiger Form
- Der Algorithmus arbeitet effizient, auch bei großen Datensätzen

Für den vorliegenden Anwendungsfall sind diese Kriterien auch wichtig, da der DBSCAN Algorithmus genutzt werden soll, um aus hellen Pixeln, die als Datenpunkte interpretiert werden, Cluster zu finden, die dann die Spuren darstellen.

Die Hauptidee des Algorithmus ist, dass jeder Punkt P einen anderen Punkt K innerhalb eines Radius ε um den Punkt aufweist. Durch dieses Kriterium ergibt sich ein so genannter Core Point. Dieser wird wie folgt beschrieben:

$$N_{\varepsilon}(P) > \text{MinPts}$$

Abbildung 24 — DBSCAN Core Point Kriterium

Die Parameter ε und MinPts können hierbei vom Anwender gewählt werden. ε stellt dabei den Radius dar, in dem eine Mindestanzahl MinPts an anderen Datenpunkten gefunden werden soll, damit P als Core Point klassifiziert wird. Der Algorithmus fährt dann fort und fügt jedem Core Point Datenpunkte aus der Umgebung zu. Wenn jedem Cluster kein neuer Punkt mehr hinzugefügt werden kann, terminiert der Algorithmus [26] (S. 233).

Innerhalb der Berechnung des Kreuzungszentrums soll der DBSCAN Algorithmus verwendet werden, um durch Clustering Linien zu bilden. Es stellt sich die Frage, ob anstatt des DBSCAN Algorithmus bereits verfügbare Linien genutzt werden können, die der Line Segment Detector berechnet. Der LSD weist dabei ein Problem auf, was durch den DBSCAN behoben werden kann, und zwar, dass Linien oft fragmentiert sind und dadurch keine eindeutige Kreuzung der Linien berechnet werden kann.

Nachdem Cluster berechnet wurden, kann durch PCA (siehe Abschnitt 5.4.3.3), eine Menge an Linien gewonnen werden, die danach miteinander gekreuzt werden. Der Mittelpunkt aller Kreuzungen ist dann die Kreuzungsmitte.

Durch Testing in der Pipeline hat sich dieser Ansatz zwar als generell sinnvoll, aber nicht optimal herausgestellt. Da durch Fusionierung in der Vorverarbeitung bereits aus sehr kleinen Segmenten repräsentative Linien berechnet wurden, werden die weiteren Rechenkosten des DBSCAN als nicht gerechtfertigt angesehen. Zudem wies dieser Ansatz bei Anfahrt aus Kurven, in weiterer Entfernung von der Kreuzung und bei Mangel an erkannten Linien starke Mängel auf und berechnete die Kreuzungsmitte teilweise außerhalb der Kreuzung, was zu vollständig falschen Klassifikationen führte. Um den Parametrierungsaufwand zu minimieren, wurden vorerst weitere Ansätze getestet.

KREUZUNG VON LSD-LINIEN Um den Berechnungsaufwand durch DBSCAN zu umgehen, stellte sich der Ansatz, Linien aus der Vorverarbeitung zu nutzen, als sinnvoll dar. Demnach könne man eben diese Linien miteinander kreuzen und dann den Kreuzungsmittelpunkt berechnen.

TODO: ausführen bzw was schreibe ich hier rein Vielleicht sogar nochmal ausprobieren?? Sonst auslassen??

HARRIS CORNER DETECTION

Ein anderer Ansatz ist es, ohne Linien zu kreuzen innerhalb des Bildes Ecken zu detektieren und durch Mitteln aller Ecken das Kreuzungszentrum zu finden. Ein etablierter Algorithmus zur Detektion von Ecken ist der Harris Corner Detector.

Der Harris Corner Detector ist ein klassischer Eckenerkennung-Algorithmus, der 1988 von Chris Harris und Mike Stephens entwickelt wurde. Der Algorithmus identifiziert Punkte im Bild, an denen sich die Bildintensität in mehreren Richtungen stark ändert – typischerweise an Ecken oder anderen strukturierten Features.

Der Algorithmus berechnet zunächst die Gradienten des Bildes in horizontale und vertikale Richtungen. Für jeden Pixel wird dann eine Auto-Korrelations-Matrix (auch Struktur-Tensor genannt) berechnet, die misst, wie sich die Bildintensität in verschiedenen Richtungen ändert. Basierend auf dieser Matrix wird eine Eckenresponse-Funktion berechnet: $R = \lambda_1 \lambda_2 - k(\lambda_1 + \lambda_2)^2$, wobei λ_1 und λ_2 die Eigenwerte der Matrix sind und k ein Tuning-Parameter (typischerweise 0.04–0.06) ist. Pixel mit hohem Response-Wert werden als Eckenpunkte klassifiziert. Der Schwellwert wird meist empirisch gesetzt.

Ein großer Vorteil des Harris Detectors ist seine Recheneffizienz und die stabile Eckenerkennung in vielen Bildern. Allerdings hat der Algorithmus einige Schwächen: Die Eckenresponse ist nicht invariant gegenüber Skalierung, was bedeutet, dass unterschiedlich große Ecken unterschiedlich bewertet werden. Außerdem ist die Wahl des Parameters k kritisch und muss oft manuell angepasst werden.

SHI-TOMASI ECKENERKENNUNG

Neben dem Harris Corner Detector gibt es außerdem den Shi-Tomasi Algorithmus zur Erkennung von Ecken.

Der Shi-Tomasi Corner Detector ist eine Variante des Harris Corner Detectors, die 1994 von Jianbo Shi und Carlo Tomasi entwickelt wurde. Der Algorithmus versucht, Eckenpunkte in einem Bild zu erkennen, indem er lokale Bereiche analysiert, in denen sich die Bildintensität in mehreren Richtungen stark ändert.

Der Algorithmus funktioniert wie folgt: Zunächst wird für jeden Pixel die Auto-Korrelations-Matrix berechnet, die angibt, wie stark sich die Bildintensität in unterschiedliche Richtungen ändert. Diese Matrix wird als Struktur-Tensor oder Harris-Matrix bezeichnet. Anstatt der bei Harris verwendeten Eckenresponse-Funktion nutzt Shi-Tomasi direkt die Eigenwerte dieser Matrix: Ein Pixel wird als Eckenpunkt klassifiziert, wenn der kleinere der beiden Eigenwerte größer als ein Schwellwert ist. Dies bedeutet, dass die Bildintensität in mindestens zwei Richtungen stark variiert. Ein großer Vorteil dieses Ansatzes ist, dass er das optische Fluss-Tracking-Problem besser löst, da er auf die tatsächliche Struktur der Bildänderungen reagiert, anstatt auf eine heuristische Eckenmetrik.

Der Shi-Tomasi Algorithmus ist robuster gegen Skalierung und Rotation von Features, was ihn für die praktische Anwendung attraktiver macht. Außerdem berechnet der Algorithmus sowohl die Position als auch eine Qualitätsmetrik für jeden erkannten Eckenpunkt, was eine nachträgliche Filterung und Bewertung ermöglicht.

Durch Testing in der Pipeline wird der Shi-Tomasi Algorithmus als Basis der Kreuzungszentrumserkennung gewählt. Die Parametrierung des Algorithmus fällt simpel aus: Es werden für die Anzahl der auszugebenden Ecken $n = 4$ gewählt, sodass die repräsentativsten Ecken (die die Ecken der Kreuzung darstellen sollen) ausgegeben. Das Shi-Tomasi Zentrum ist dabei das Mittel der gefundenen Ecken.

5.6.3 Hybrider Ansatz zur Kreuzungsmittenberechnung

Obwohl Shi-Tomasi zufriedenstellende Ergebnisse liefert, kommt es auch zu Berechnungen von Kreuzungsmitten, die eine hohe Abweichung zum tatsächlichen Zentrum aufweisen. Um dem entgegenzuwirken, sollen Eckpunkte zuerst validiert werden, bevor ein Kreuzungszentrum berechnet wird.

Eine grundlegende Idee wäre es, zu prüfen, ob die Innenwinkelsumme der vier gefundenen Ecken 360° ist. Dieser Ansatz wird verworfen, da Eckpunkte in verschiedenen Anordnungen, die nicht unbedingt ein Viereck sein müssen, auch 360° ergeben. Stattdessen werden nun die einzelnen Winkel an den Ecken berechnet, die für ein Viereck jeweils 90° ergeben müssen. Um eine Metrik zu gewinnen, die die Ähnlichkeit der Anordnung der Ecken zu einem Viereck darstellt, werden die jeweiligen Fehler an jeder Ecke zu 90° berechnet und dann der Durchschnitt über alle vier Ecken gebildet. Anhand dieser Metrik kann nun bestimmt werden, ob das Shi-Tomasi Zentrum genutzt wird oder nicht.

Außerdem wird zusätzlich ein Gedächtnissystem eingebaut. Wird ein valides Shi-Tomasi Zentrum gefunden, wird dieses für fünf Frames gehalten. Es ändert dann in jedem Frame seine Position um einen festgelegten Pixelwert entlang der Hauptausrichtung der Linien. Dieses Tracking erzeugt selbstverständlich keine Ergebnisse, die an die eines Kalman-Filters herankommen. Da die Anzahl der Frames, die das Zentrum gespeichert wird, aber relativ klein mit Blick auf die Framerate der Kamera ist, ist diese Näherung zufriedenstellend und liefert Ergebnisse, die gut für die Detektion von Linien genutzt werden können.

Kann kein Shi-Tomasi Zentrum berechnet werden, wird weiterhin das Zentrum der ROI als Redundanz angenommen.

5.6.4 Pipeline zur Kreuzungszentrumserkennung

Aus den gesammelten Erkenntnissen ergibt sich folgende Pipeline zur Erkennung des Kreuzungszentrums.




Abbildung 25 — Pipeline für Kreuzungszentrumserkennung

5.6.5 Erweiterung der Kreuzungsmitte

Bei der Kreuzungsmittenerkennung kommt es vereinzelt zu Berechnungen von Mitten, die nicht exakt in der tatsächlichen Mitte der Kreuzung liegen. Das ist allgemein unproblematisch für die Erkennung von Haltelinien, kann aber vereinzelt dazu führen, dass Haltelinien später erkannt werden als es möglich wäre oder das System in einigen Frames Haltelinien verliert. Grund dafür ist, dass aufgrund der Logik, die nächste Linie zum Kreuzungszentrum zu suchen, falsche Linien als Haltelinien klassifiziert werden. Die tatsächliche Haltelinie und eine sehr nah an dieser liegende „kämpfen“ um die Klassifikation als Haltelinie.

Um dieses Problem zu lösen, werden weitere Referenzpunkte aus der Kreuzungsmitte berechnet. Für die Ego- und Opplinie liegen diese entlang des Hauptwinkels der Linie und für die rechte und linke Haltelinie orthogonal dazu. Da die Referenzpunkte näher an dem tatsächlichen Bereich liegen, in denen die Haltelinien zu vermuten sind, werden auch die korrekten Haltelinien als diese klassifiziert.




Abbildung 26 — Berechnete Kreuzungsmitte mit Referenzpunkten (Autor)

5.7 Klassifizierung der Linienart

Neben der Lokalisation der Haltelinien muss auch erkannt werden, um welche Art es sich bei der haltelinie handelt. Haltelinien können sowohl gestrichelt als auch durchgezogen sein.

Um dies zu bestimmen, wird ein Algorithmus implementiert, der eine Linie und das Rohbild als Input erhält und den Weißanteil der Linie als auch die Anzahl der Lücken entlang der Linie ausgibt.

5.7.1 Linienausschnitt

Zu Beginn wird die Linienmitte bestimmt. Nun wird entlang des Linienzentrums rotiert, sodass die Linie waagrecht im Bild liegt. Dafür wird folgender Code genutzt.

python

```

1 h, w = image.shape[:2]
2 M = cv2.getRotationMatrix2D((mid_x, mid_y), angle, 1.0)
   Die Linienmitten und der Linienwinkel wurden vorher berechnet
3 warped = cv2.warpAffine(image, M, (w, h), flags=cv2.INTER_LINEAR)

```

Abbildung 27 — Rotation des Bildes um das Linienzentrum

Die Funktion `cv2.getRotationMatrix2D` berechnet dabei eine Rotationsmatrix mit der außerdem eine Verschiebung möglich ist. Das ist nötig, da nicht um den Ursprung rotiert wird. Eine Rotationsmatrix um den Ursprung sieht wie folgt aus.

$$R = \begin{bmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{bmatrix} \quad (5)$$

Da nun aber nicht um den Ursprung, sondern durch einen beliebigen Punkt im Bild rotiert wird die Matrix um konstante Werte erweitert, anhand derer alle Punkte um einen beliebigen Punkt im Bild verschoben werden können.

$$R = \begin{bmatrix} \cos(\theta) & -\sin(\theta) & t_x \\ \sin(\theta) & \cos(\theta) & t_y \\ 0 & 0 & 1 \end{bmatrix} \quad (6)$$

Nun wird das Zentrum der ursprünglichen Linie in das rotierte Bild transformiert.

Jetzt wird der Ausschnitt um die Linie aus dem rotierten Bild ausgeschnitten. Der Ausschnitt wird so ausgeschnitten, dass sowohl zu den Seiten als auch oben und unterhalb der Linie Abstand besteht (siehe Abbildung 34).

5.7.2 Weißwertberechnung

Es ist unabdinglich, in verschiedenen Lichtverhältnissen zuverlässig den Weißwert der Linie berechnen zu können. Die Annahme ist, dass neben den weißen Pixeln des Ausschnitts auch graue oder nahezu weiße Pixel um den Linienabschnitt selbst liegen können. Dies kann etwa durch Sonneneinstrahlung passieren.

Um dem entgegenzuwirken, wird der Ausschnitt vorverarbeitet. Um das Bild unabhängig von Lichtverhältnissen nutzbar zu machen, müssen graue bis weiße Bildbereiche, die aber nicht zur Linie gehören, unterdrückt werden. Dafür wird zuerst der Canny-Algorithmus verwendet, um Pixel zu finden, die tatsächlich zur Linie gehören könnten. Daraus wird eine Pixelmaske generiert, die anschließend genutzt wird, um die originalen Pixelwerte der Pixel aus dem Bildabschnitt auszulesen. Es wird der Median dieser Pixelwerte gebildet. Falls der Canny-Algorithmus kein Ergebnis geliefert hat, wird der Median des ganzen Ausschnitts berechnet.

Der Ansatz, um für die Berechnung interessante Pixel, also die Pixel, die tatsächlich zur Linie gehören, gegenüber Hintergrundpixeln hervorzuheben, besteht in einer Verschiebung der Pixelwerte mit der Sigmoid-Funktion. Diese ist wie folgt beschrieben:

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (7)$$

Abbildung 30 — Sigmoid Funktion

Mit der Sigmoidfunktion wird nun eine kontrastverstärkenden, nicht lineare Normalisierung der Pixelwerte innerhalb des Ausschnitts durchgeführt. Dafür werden zuerst die Pixelwerte normalisiert, indem sie zuerst um den Medianwert verschoben und dann durch 50 dividiert werden. Die Division hat den Hintergrund, dass die Sigmoid Funktion nur etwa im Bereich $+/-3$ effektiv normalisiert (siehe Abbildung 31). Das heißt, dass eine Intensitätsänderung um $+/-150$ zu einer vollständigen Sättigung in der Sigmoidfunktion führt, was für die Pixelwerte 0-255 gut passt.




Abbildung 31 — Visualisierung der Sigmoid-Normalisierungsfunktion

Nun werden durch die Sigmoidfunktion Intensitätswerte, die nah am Median liegen in Richtung der 0.5 normalisiert. Werte, die weiter unter dem Median liegen, werden in Richtung 0 normalisiert. Werte über dem Median in Richtung 1 (Abbildung 31). Jetzt werden die berechneten Werte wieder mit Faktor 255 skaliert.

Im nächsten Schritt wird adaptives Thresholding genutzt, um die tatsächliche Segmentierung der Linie vom Hintergrund durchzuführen. Durch das adaptive Thresholding wird noch einmal sichergestellt, dass Lichtinvarianzen nicht ins Gewicht fallen und das Liniensegment sicher erkannt wird, da es keinen globalen Threshold für ein Bild ermittelt. Das adaptive Thresholding nutzt lokale Thresholdermittlung für jeden Pixel.

Es werden nun gewonnene Informationen in einer einzigen Bitmaske zusammengefasst, die einen Minimalintensitätswert für die Linienspixel voraussetzt, die aber auch durch das adaptive Thresholding als zur Linie zugehörig klassifiziert wurden.

python

```
1 binary = (gray >= 60).astype(np.uint8) & adaptive_binary
```

Abbildung 32 — Bitmaske des Liniensegments für die Weißanteilberechnung

Nun wird das Bild in ein 1D Spaltenprofil umgewandelt, indem die Anzahl der weißen Pixel in jeder Spalte summiert werden (siehe Abbildung 34). Mit Hilfe dieses Wertes und der Gesamtgröße des Ausschnitts wird nun der Weißanteil der Linie am Ausschnitt berechnet. Dieser Wert kann zur Validierung von Linien verwendet werden. Detektierte Linien, die tatsächlich aber nicht auf realen Linien liegen, weisen dabei einen sehr geringen Weißanteil im Ausschnitt auf und können somit ausgefiltert werden.

5.7.3 Gap-Detektion

Um zu bestimmen, ob es sich bei Linien um gestrichelte oder durchgezogene Halte-
linien handelt, werden die Lücken zwischen den weißen Teilen einer Linie berechnet.
Im Schritt zuvor wurde ein Spaltenprofil des Ausschnitts angelegt, welches die Anzahl

weißer Pixel pro Spalte aufsummiert anzeigt. Dieses Profil wird nun genutzt. Dabei werden die Spalten nach folgendem Algorithmus berechnet Abbildung 33.

```

1 Iteriere über die Spalten i des Spaltenprofils
2   Falls Wert bei i (Summe der weißen Pixel) == 0:
3     Falls bereits in einer Lücke, gap_size++
4     Falls noch in keiner Lücke
5       Setze in_gap auf 1
6   Falls Wert bei i > 0 Setze in_gap auf 0 und resette gap_size
7     Falls in_gap == 1 & gap_size > min_gap_size
8       gaps++
9 Falls nach Beenden der Schleife noch in_gap == 1, inkrementiere Gap-Anzahl
10 Gebe gaps zurück

```

Abbildung 33 – Lückenerkennungsalgorithmus

Schließlich wird über einen Parameter `min_gap_count` bestimmt, wann eine Linie gestrichelt ist. Durch Tests hat sich `min_gap_count=3` als optimaler Parameter für die Funktion ergeben.




Abbildung 34 – Gap-Detektion (Autor), links Gesamtbild, rechts Analyseabschnitt mit Canny-Bild und 1D-Spaltenprofil

5.7.4 Pipeline zur Klassifizierung der Linienart

Nachdem nun die algorithmische Basis der Klassifizierung der Linienart näher erläutert wurde, wird nochmal eine Übersicht über die genutzte Pipeline innerhalb des Moduls gegeben.




Abbildung 35 – Pipeline für die Klassifizierung der Linienart

5.8 Heading der Straße

Ein bisher beständiges Problem der Kreuzungserkennung ist die falsche oder ausgelassene Detektion von Haltelinien bei Anfahrt aus einer Kurve. Zusätzlich hängt die Ausrichtung der abgeleiteten Kreuzungsmitten (siehe Abschnitt 5.6.5) auch von der Orientierung der Straße ab und ändert sich deshalb bei Anfahrt aus Kurven.

5.8.1 Gaussian Mixture Model mit Expectation Maximization

Eine verwandte Methode zur Bestimmung der Straßenorientierung ist die Lenkwinkelberechnung für autonome Fahrzeuge. Ein vielversprechender Ansatz, der in der Literatur beschrieben wird, nutzt Computer Vision mit geringen Rechenkosten. Die Methode basiert auf drei Schritten: Zunächst wird die befahrbare Straßenregion mittels Gaussian Mixture Model (GMM) mit Expectation Maximization (EM) extrahiert, um robust mit Schatten und verschiedenen Lichtverhältnissen umzugehen. Daraufhin werden die Straßengrenzen durch Canny Edge Detection detektiert. Abschließend wird der Lenkwinkel aus dem Schnittpunkt der extrahierten Grenzen berechnet – also dem Punkt, in dem sich die extrapolierten Straßenkanten treffen. Der Winkel zwischen diesem Schnittpunkt und der Fahrtmitte ergibt dann die erforderliche Fahrtrichtung. Zur Rauschunterdrückung werden Kalman-Filter eingesetzt, um abrupte Lenkwinkeländerungen durch Fahrbahnunebenheiten oder Umgebungsrauschen zu glätten [27].

Dieser Ansatz ist interessant für die Kreuzungserkennung, da die Straßenorientierung direkt aus dem aktuellen Kamerabild ermittelt werden kann, ohne zusätzliche Sensoren wie LIDAR oder RADAR zu benötigen. Die Methode funktioniert auch auf unstrukturierten Straßen und unter verschiedenen Lichtverhältnissen, was für realistische Einsatzszenarien vorteilhaft ist [27].

Für den vorliegenden Anwendungsfall ist die Methodik nutzbar, erscheint aber aufgrund der bereits berechneten Liniensegmente in ihrem Umsetzungsaufwand zu groß.

5.8.2 Deep Learning basierter Ansatz

Neben dem zuvor vorgestellten Computer Vision basierten Algorithmus zur Berechnung des Heading Winkels gibt es auch zahlreiche Methodiken, die auf Basis von trainierten Modellen arbeiten. Beispielsweise können die Convolutional Neural Networks (CNN) sein [28]. Dafür muss ein großer Datensatz akquiriert und annotiert werden, bevor ein neuronales Netz zu trainieren. Dieses kann dann auf Basis der Trainingsdaten den Heading Winkel auf Realdaten vorraussagen [28].

Auch dieser Ansatz erscheint für den vorliegenden Anwendungsfall unpassend, da er eine Akquise eines annotierten Trainingsdatensatzes voraussetzt. Außerdem ist ein Ansatz mit geringeren Rechenkosten möglich.

5.8.3 Histogrammbasierter Ansatz

Im Folgenden wird ein weiterer Ansatz erläutert, der auf der Berechnung des Heading Winkels über Histogramme aller erkannten Linien basiert.

Dafür werden in einem ersten Schritt Linien nach ihrer Ausrichtung sortiert. Dabei werden nur Linien zur Berechnung des Winkels genutzt, die im Winkelbereich $45^\circ \leq \alpha \leq 135^\circ$ liegen.

Nun wird aus den Winkeln aller validen Linien ein Array erstellt, welches zum erstellen eines Histogramms genutzt wird. Die Grundidee ist es, die dominante Ausrichtung der Linien im aktuellen Bild zu finden. Dafür wird folgender Code verwendet.

python

```
1 valid_angles_arr = np.array(valid_angles)
2 bins, range = 18, (45, 135)
3 hist, bin_edges = np.histogram(valid_angles_arr, bins=bins, range=range)
4 peak_bin = int(np.argmax(hist))
5 prominent_angle = float((bin_edges[peak_bin] + bin_edges[peak_bin + 1]) /
6 2.0)
```

Abbildung 36 — Berechnung eines Histogramms über Winkel der Spurlinien

TODO: CODE ÄNDERN IN DER REPO (WENIGER BINS UND ANDERE RANGE)

In einem ersten Schritt wird ein Histogramm aus 18 Bins in einem Bereich von (45, 135) erstellt. Dadurch ist eine Auflösung von $\frac{135^\circ - 45^\circ}{18} = 5^\circ$ festgelegt. Diese ist grob gewählt, da durch die Fusion der Linien in der Vorverarbeitung eine relativ geringe Anzahl an Linien für die Histogrammbildung in Frage kommt. Es wird nach der Histogrammbildung die Bin mit den größten Anzahl an Elementen ausgewählt. Dies ist die dominante Ausrichtung aller vertikalen Linien im aktuellen Bild. Dadurch, dass der Bereich mit [45; 135] festgelegt wird, kann der dominante Winkel folglich auch nur in diesem Bereich liegen. Das ist aber für den Anwendungsfall sinnvoll, da das Fahrzeug im Normalbetrieb mit einem Heading-Winkel fährt, der nicht außerhalb dieses Bereichs fällt. Wäre dies der Fall, würde eine Situation vorliegen, in der das Fahrzeug nicht korrekt auf der Straße platziert oder von dieser abgekommen ist. In diesem Fall wäre die Kreuzungserkennung deaktiviert.

Zuletzt wird der Durchschnitt des Bins peak und des Bins $\text{peak} + 1$ berechnet. Dies ist der Tatsache geschuldet, dass die Peakbin nur den unteren Rand des tatsächlichen Ergebnisses abbildet und die $\text{Bin peak} + 1$ den oberen Rand. Der Durchschnitt dieser approximiert den tatsächlichen Winkel.

5.8.4 Pipeline zur Headingwinkel Berechnung

Aus der nun beschriebenen Methodik ergibt sich folgenden Pipeline, die innerhalb des Systems zur Approximierung des Heading Winkels verwendet wird (Abbildung 37). Es wird der histogrammbasierte Ansatz gewählt, da dieser schnell implementiert werden konnte und zudem keine Vorbereitung eines annotierten Trainingsdatensatzes verlangt. Außerdem ist dieser Ansatz schnell und erfordert im Gegensatz zu den anderen vorgestellten Ansätzen wenig Rechenkosten.




Abbildung 37 — Pipeline für die Berechnung des Heading-Winkels

5.9 Postprocessing der Ego- und Opplinie

Nachdem das System die Egolinie und die Opplinie erkannt hat, werden diese nachverarbeitet und validiert. Dadurch können Ergebnisse verbessert und Fehldetektionen minimiert werden.

Die folgenden Schritte werden sowohl für eine erkannte EgoLinie als auch für eine erkannte Opplinie durchgeführt. Die Parameter der einzelnen Funktionen unterscheiden sich jedoch.

5.9.1 Linienpräzisierung

Die Idee, eine erkannte Linie zu präzisieren, basiert darauf, dass Linien je nach Heading der Straße an anderen Stellen zu erwarten sind, als wenn das Fahrzeug geradeaus auf eine Kreuzung zufährt. Außerdem wird ausgenutzt, dass für eine zuverlässige Navigation des Fahrzeugs und ein sicheres Halten vor der Haltelinie die Länge der Linie selbst keine große Relevanz hat. Wichtiger ist die tatsächliche Position. Deswegen wird im ersten Schritt die Linie verlängert. Nun wird die Linie in einem bestimmten Clipbereich abgeschnitten, an der sie bei Anfahrt aus dem aktuellen Winkel zu erwarten ist. Damit wird gewährleistet, dass selbst bei einer Detektion einer Ego- oder Opplinie, die relativ zu der tatsächlichen Lage im Bild falsch positioniert ist, eine Verbesserung der Lokalisierung erreicht werden kann.

Der Clipbereich der Linie ist ein rechteckiger Sektor, der von der oberen Kante der ROI bis zur unteren Kante der ROI reicht. Die Position dieses Clipbereichs entlang der x-Achse ändert sich als Funktion des Headingwinkels. Die Idee ist, dass der Clipbereich der Ego Linie bei Frontalanfahrt an die Kreuzung bei $[0.5 * W_{ROI}; 0.75 * W_{ROI}]$ liegt, wobei W_{ROI} die Breite der Region of Interest ist. Dort ist die EgoLinie zu erwarten, wenn das Fahrzeug frontal auf die Kreuzung zufährt. Die Opplinie liegt bei solch einer Anfahrt im Bereich $[0.15 * W_{ROI}; 0.4 * W_{ROI}]$. Diese Bereiche wurden durch Testing ermittelt.

Dieser Clipbereich wird adaptiv je nach Headingwinkel angepasst. Fährt das Fahrzeug aus einer Kurve an die Kreuzung heran, müssen die Clipbereiche der E- und O-Linie fast übereinander liegen. Ohne adaptive Anpassung würde das Modul die Linien in einer falschen Position vermuten.

In Abbildung 38 ist qualitativ die Berechnung der neuen Position der rechten und linken Ränder des Clipbereichs für die O-Linie bei einer Linkskurve zu sehen. Es wird auf Basis des Heading ein Faktor zwischen 0 und 1 berechnet, welcher dann mit Basiswerten für die Position des linken und rechten Randes des Clipbereichs multipliziert wird, sodass bei vollem Einschlag ein Bereich $[0.05 * W_{ROI}; 0.25 * W_{ROI}]$ berechnet wird. Dies wird analog auch für eine rechte Kurve mit den Maximalwerten $[0.48 * W_{ROI}; 0.7 * W_{ROI}]$ und die EgoLinie gemacht. (da werte auch einfügen?)

python

```
1 angle_factor = (90.0 - angle) / (90.0 - 70.0)
2 angle_factor = min(1.0, max(0.0, angle_factor))
3 min_rel = min_rel_base + angle_factor * (0.05 - min_rel_base)
4 max_rel = max_rel_base + angle_factor * (0.25 - max_rel_base)
```

Abbildung 38 — Adaptives Clippen der Haltelinien, hier O-Linie, Qualitativ

5.9.2 Linienumgebung

Es ist möglich, dass Linien als Ego- und Opplinie erkannt werden, die zu einer Spur oder einer Sperrfläche gehören. Um hierdurch Falschklassifikationen zu vermeiden, wird angenommen, dass tatsächliche Egolinien bei Erweiterung nach links nicht fortlaufend sind. Legt man somit eine *Prüffläche* mit einem bestimmten Abstand links neben die erkannte Egolinie und prüft, ob die Pixel um diese Prüflinie hell sind, handelt es sich nicht um eine reale Egolinie. Bei der Opplinie macht man dies zur rechten Seite.

Die Berechnung der Prüflinie geschieht durch Berechnung aller vier neuen Koordinaten der Linie. Der Startpunkt der Prüflinie (x_s und y_s) wird mit $x_s = x + d$ und y_s mit $y + m * d$ berechnet. Analog dazu werden die Enden der Prüflinie x_e und y_e nach der selben Formel mit x_s und y_s als Startpunkte berechnet. Als Initialabstand d von der ursprünglichen Linie wird 40 gewählt. Als Länge der Prüflinie an sich wird ein Wert von 50 gewählt. Die Weißdichte unter der Linie wird nach der Methode aus Abbildung 35 berechnet.

5.9.3 Validierung von Querlinienpaaren

Ferner wird die Position der Ego- und Opplinie vom Kreuzungszentrum und die Abstände der Linien zueinander (Höhe und Breite) auf Plausibilität geprüft. Bei der Erkennung von Querlinien (Stop-Linien) können sowohl einzelne als auch Paare von Linien auftreten. Die Funktion `check_stop_line_pair_plausibility()` validiert diese Linien nach plausiblen geometrischen Kriterien.

Die Validierungslogik arbeitet nach folgendem Schema:

1. **Beide Linien sind None:** Das Paar wird als ungültig zurückgewiesen.
2. **Genau eine Linie ist None:** Die vorhandene Linie wird als gültig akzeptiert, da eine einzelne Stop-Linie zulässig ist.
3. **Beide Linien existieren:** Es werden vier Kriterien überprüft:

- **Vertikale Ausrichtung:** Die durchschnittlichen y-Koordinaten beider Linien müssen innerhalb einer Toleranz von $\text{max_y_diff} = 30$ Pixeln liegen. Sind die Linien zu weit auseinander, werden sie als Falschdetektionen verworfen.
- **Horizontale Separation:** Der horizontale Abstand zwischen den Mittelpunkten muss im Bereich von $\text{min_x_separation} = 50$ bis $\text{max_x_separation} = 200$ Pixeln liegen. Ein zu kleiner Abstand deutet auf Duplikate hin, ein zu großer auf unabhängige Artefakte.
- Bei Erfüllung aller Kriterien wird das Linienpaar als valide zurückgegeben.
- Bei Verletzung wird (None, None) zurückgegeben.

Die durchschnittliche y-Position einer vertikalen Linie wird als $y_{\text{avg}} = \frac{y_1 + y_2}{2}$ berechnet, analog die x-Position als $x_{\text{avg}} = \frac{x_1 + x_2}{2}$. Dies vereinfacht die Positionsvergleiche und macht sie robuster gegen kleinere Erkennungsabweichungen.

5.10 Plausibilisierung vertikaler Haltelinien

Auch die rechte und linke Haltelinie werden validiert. Diese Validierung folgt analog der Validierung der Ego-Haltelinie und der Gegenspurhaltelinie und ist in Abschnitt 5.9.2 beschrieben.

In einem weiteren Schritt werden auch die vertikalen Haltelinien nach einigen geometrischen Kriterien herausgefiltert. Dabei werden zwei separate Validierungsfunktionen für die linke und rechte Stop-Linie verwendet. In einem weiteren Schritt werden auch die vertikalen Haltelinien nach einigen geometrischen Kriterien herausgefiltert. Die rechte Stop-Linie muss oberhalb der Kreuzung liegen, innerhalb der ROI-Grenzen platziert sein und rechts des Kreuzungsmittelpunkts positioniert sein. Die linke Stop-Linie muss symmetrisch dazu links des Kreuzungsmittelpunkts liegen. Linien, die diese Bedingungen nicht erfüllen, werden als Falschdetektionen verworfen.

Nun wird die Dicke der Haltelinien gemessen. Diese unterscheidet sich von der Dicke einer Spur. Damit können Falschklassifikationen während der Anfahrt auf eine Kreuzung oder beim Herausfahren durch Verwechslung mit der Fahrspur ausgeschlossen werden.

5.11 Ergebnisaggregator

Die Kreuzungserkennung arbeitet framebasiert und besitzt kein „Gedächtnis“, welches Klassifikationen aus älteren Frames speichert. Das führt zu Problemen, da das System in dem Fall, dass eine Haltelinie in einem Frame nicht erkannt wird, sofort das

Ergebnis ändert. Hat das System nun mehrere Frames hintereinander die Kreuzung richtig erkannt, verliert aber in einem Frame die Erkennung, kann die Ausgabe eines falschen Ergebnisses Probleme bei andere Modulen wie der Routenplanung auslösen.

Um dieses Problem zu lösen wird ein Ergebnisaggregator eingebaut. Dieser soll als Gedächtnis des Systems arbeiten. Es gibt mehrere Methoden, ein solches Gedächtnis zu implementieren. Eine bewährte Methode ist die Verwendung eines Kalman-Filters.

KALMAN-FILTER

Der Kalman-Filter ist ein iterativer Algorithmus, der Messungen mit Unsicherheiten kombiniert, um eine optimale Schätzung des Systemzustands zu produzieren. Er funktioniert in zwei Phasen: der Vorhersagephase (Prediction) und der Aktualisierungsphase (Update).

In der Vorhersagephase wird der nächste Zustand basierend auf einem Systemmodell und der bisherigen Schätzung vorhergesagt. In der Aktualisierungsphase wird die Vorhersage mit einer neuen Messung kombiniert, um eine verbesserte Schätzung zu erhalten. Der Filter gewichtet dabei automatisch, wie sehr der Schätzung oder der Messung zu trauen ist, basierend auf deren Unsicherheiten.

Für die Kreuzungserkennung kann der Kalman-Filter verwendet werden, um die erkannten Haltelinien über mehrere Frames hinweg zu glätten. Wenn eine Haltelinie in einem Frame nicht erkannt wird, behält der Filter eine Vorhersage basierend auf den vorherigen Frames bei, statt sofort das Ergebnis zu ändern. Dies führt zu robusteren Erkennungsergebnissen.

BUFFERBASIERTER AGGREGATOR

Im vorliegenden System wird statt eines klassischen Kalman-Filters ein bufferbasiertes Aggregatorsystem verwendet. Dieses System verwaltet für jede Haltelinienart (Ego, Opp, Stop-Links, Stop-Rechts) einen Konfidenzpuffer im Bereich von 0.0 bis 1.0. Diese Buffer dienen als „Gedächtnis“ des Systems über mehrere Frames hinweg.

Der Mechanismus funktioniert nach dem Prinzip der exponentiellen Glättung. Wird eine Haltelinie in einem Frame erkannt, erhöht sich der entsprechende Buffer um einen festgelegten Inkrementwert. Wird sie nicht erkannt, sinkt der Buffer um einen Dekrementwert. Der Inkrementwert und der Dekrementwert sind für jeden Linientyp unterschiedlich kalibriert. Beispielsweise hat die Opp-Linie einen höheren Inkrementwert (0.25) als die Ego-Linie (0.18), da die Opp-Linie in der Regel zuverlässiger erkannt wird.

Jeder Linientyp hat zudem einen individuellen Schwellenwert. Die Haltelinie wird als valide ausgegeben, wenn ihr Buffer diesen Schwellenwert überschreitet. Dadurch wird verhindert, dass einzelne Erkennungsausfälle zu Sprüngen in der Ausgabe führen. Ein erkannter Frame erhöht zwar den Buffer, reicht aber nicht aus, um den Ausgabewert sofort zu ändern. Dafür sind mehrere konsistente Erkennungen nacheinander nötig.

Das System berechnet zusätzlich ein Stabilitätsmaß basierend auf der Historie der Bufferwerte über die letzten Frames. Ein stabiler Buffer bedeutet weniger Rauschen und erhöht das Vertrauen in die aktuelle Erkennung. Die Gesamtkonfidenz wird aus den durchschnittlichen Bufferwerten aller vier Linientypen berechnet und mit dem Stabilitätsmaß gewichtet. Dies ergibt einen Konfidenzwert zwischen 0.0 und 1.0, der die Zuverlässigkeit der aktuellen Kreuzungserkennung angibt.

Der Aggregator gibt schließlich über die Methode `get_crossing_type()` die aktuelle Klassifikation der Kreuzung anhand eines Strings aus, der nach folgendem Schema aufgebaut ist: `eX-oX-lX-rX`. Die Präfixe stehen für die einzelnen Haltelinien (Ego, Opp, Left, Right) und das X kann folgende Werte annehmen: `n-None`, `s-solid`, `d-dotted`. Der Aggregator liefert somit die Gesamtklassifikation als Ergebnis der Pipeline, welches wie folgt aussehen könnte: `es-os-ln-rn`.

5.12 Bild zu Welt Transformation



Konzeption einer Sperrflächenerkennung

Im Laufe der Entwicklung wurde versucht, eine zusätzliche Sperrflächenerkennung zu implementieren, um gekennzeichnete Parkplätze und Sperrflächen in der Umgebung des Fahrzeugs zu detektieren. Dies würde dem autonomen Fahrzeug ermöglichen, solche Bereiche zu erkennen und sie bei der Planung von Bewegungsmanövern zu berücksichtigen.

Die Implementierung folgte einem ähnlichen Ansatz wie die bestehende Kreuzungserkennung, nutzte aber modifizierte Parameter. Die Pipeline begann mit der gleichen Linienerkennung aus der Bildvorverarbeitung. Statt jedoch nach horizontalen und vertikalen Linien zu filtern (wie in der Kreuzungserkennung), wurde bei der Sperrflächenerkennung nach Linien gefiltert, die einen Winkel im Bereich von 45° bis 135° aufweisen. Dies zielt darauf ab, die diagonalen oder schrägen Begrenzungslinien von Parkplätzen und Sperrflächen zu erfassen.

Nach der Winkelfilterung wurden die erkannten Liniensegmente mittels DBSCAN (Density-Based Spatial Clustering of Applications with Noise) klassifiziert. Dieser Algorithmus gruppiert räumlich nah beieinander liegende Linien zu Clustern, wodurch zusammenhängende Flächengrenzen identifiziert werden können. Um die Geometrie dieser Cluster besser zu analysieren, wurde eine Hauptkomponentenanalyse (PCA) durchgeführt. Die PCA reduzierte die Dimensionalität der Liniensegmente und identifizierte die Hauptrichtung und Ausdehnung der erkannten Sperrflächen.

Trotz des konzeptionell vielversprechenden Ansatzes stellte sich in der praktischen Umsetzung heraus, dass die Robustheit dieser Sperrflächenerkennung begrenzt war. Die Parametrisierung des DBSCAN-Algorithmus erwies sich als kritisch und abhängig

von den spezifischen Szenen-Charakteristiken. In komplexen Umgebungen mit vielen Linien wurde der Algorithmus anfällig für Fehlclusterungen. Zusätzlich zeigte sich, dass die Winkelfilterung auf 45° – 135° zu restriktiv war und viele echte Sperrflächenkandidaten ausschloss. Aufgrund dieser Limitationen wurde die Sperrflächenerkennung in der endgültigen Pipeline deaktiviert und bleibt eine Aufgabe für zukünftige Verbesserungen.

TODO: hier noch einfügen verweise zu den algos, die ich schon erklärt hatte in dem anderen teil

TODO: BILD einfügen

TODO: pipeline diagramm einfügen

7

Evaluation

Zur Validierung des Systems werden Aufnahmesequenzen von Testfahrten des Fahrzeugs genutzt. Diese werden durch den Kreuzungsdetektor ausgewertet und danach gegen Referenzdaten („Ground Truth“) verglichen.

7.1 Labeling der Daten

Zum Labeling der Daten, also dem Erstellen von Referenzdaten zum Vergleich mit den tatsächlichen Detektionen des Kreuzungsdetektors wird ein selbst erstelltes Python Skript verwendet, in welchem mit Tkinter eine Benutzeroberfläche entwickelt wurde (siehe Abbildung 39).




Abbildung 39 — Python Tkinter Labeling Tool (Autor)

Innerhalb dieser Benutzeroberfläche ist es möglich, einen Ordner mit Prädiktionsbildern des Detektors auszuwählen. Diese enthalten das zu dem Zeitpunkt gehörige

Kamerabild und die aktuelle Detektion des Detektors visualisiert innerhalb des roten Quadrats in der oberen rechten Ecke des Bildes. Ferner kann ausgewählt werden, ob die Prädiktion korrekt ist und welche Ground-Truth diesem Bild zugrunde liegt. Das Ergebnis wird dann in einer CSV-Datei mit den Spalten: (1) Bildpfad, (2) Korrektheit der Prädiktion und (3) der Ground-Truth gespeichert. Im Allgemeinen wird für eine Darstellung einer Kreuzung ein Stringdarstellung der aktuellen Haltelinienkonfigurationen benutzt, die in Abschnitt 5.11.0.2 beschrieben ist. Eine beispielhafte Konfiguration könnte somit es-os-ln-rn sein, welche eine Kreuzung mit durchgezogener Ego- und Opplinie und fehlenden Haltelinien rechts und links bezeichnet.

Die erstellte CSV-Datei wird nach dem Labelingprozess zur Berechnung von Kernmetriken benutzt, welche im Folgenden beschrieben werden.

7.2 Metriken

7.2.1 Primäre Performance-Metriken

GESAMTGENAUIGKEIT (GLOBAL ACCURACY) Die Globale Accuracy gibt an, wieviele Frames des gesamten Datensatzes vom System korrekt erkannt wurden. Sie wird folglich mit dieser Formel berechnet:

$$\text{Accuracy} = \frac{\text{Anzahl korrekter klass. Frames}}{\text{Gesamtanzahl } N \text{ der Frames}}$$

Abbildung 40 – Berechnungsvorschrift Global Accuracy

KLASSENSPEZIFISCHE GENAUIGKEIT Nun wird die Genauigkeit auf alle einzelnen Klassentypen heruntergebrochen (also beispielsweise nur en-on-ln-rn, also keine Kreuzung, oder es-on-ln-rn). Wird nun eine Klassengenauigkeit p für eine bestimmte Klasse K erzielt, heißt es, dass das System den Anteil p der Frames, die die Ground-Truth der Klasse K haben, richtig klassifiziert hat.

7.2.2 Verteilungsmetriken

Diese Metrik zeigt an, wie die einzelnen Klassen in dem jeweiligen Datensatz verteilt sind, also wie gut der Datensatz ausbalanciert ist. Wird nun als Testdatensatz eine gesamte Fahrt mit Streckenabschnitten ohne Kreuzungen gewählt, überwiegt die Anzahl an Frames, bei denen keine tatsächlich relevanten Streckenabschnitte vorkommen.

7.2.3 Qualitative Fehlermetriken

Am Ende werden die aufgetretenen Fehler (die fehlgeschlagenen Frames) qualitativ in zwei Kategorien unterteilt. Diese sind einmal **False Positives**, also die Anzahl an Frames, an denen das System fälschlicherweise etwas erkannt hat (Geisterlinien). Zum anderen sind das **False Negatives**, also Linien, die das System nicht klassifiziert hat oder wo es falsch klassifiziert hat.

7.3 Datensatz 1

Um den Detektor auf einem allgemeinen Datensatz zu testen, wird eine Fahrt genutzt, die neben Anfahrten von Kreuzungen auch das Durchfahren von Streckenabschnitten ohne Kreuzungen enthält. Dazu ist zu sagen, dass eine solche Situation für die CauDri Challenge von keiner Bedeutung ist, da der Detektor erst bei Detektion eines Kreuzungsschildes eingeschaltet wird. Für einen ersten Überblick über die Leistung des Detektors wird eine solche Sequenz trotzdem herangezogen. Die Testfahrt wird mit $N = 286$ Frames abgebildet und enthält mehrere Kreuzungstypen sowie Abschnitte ohne Kreuzungen.

Zuerst werden die Klassifikationen des System strikt nach korrekt und falsch bewertet. Das ist für einen allgemeinen Überblick sinnvoll, ist aber im Kontext der realen Fahrsituation im Gesamten keine ausschlaggebende Bewertung. So kommt es beispielsweise nach einer erfolgreichen Detektion einer Haltelinie zu Flackern danach. Das Fahrzeug wird aber bei erfolgreicher Detektion zum Halt kommen. Somit sind mögliche flackernde Frames keine tatsächliche Störungsquelle für das Fahrzeug.

7.3.1 Evaluation der Kreuzungserkennung (Baseline)

Analysierte Datensätze (\$N\$): 286

Globale Accuracy: 81,12 %

Kreuzungstyp (Ground Truth)	Anzahl	Verteilung	Accuracy
NO_LINE	205	71,7 %	85,4 %
en-os-ln-rn	13	4,5 %	69,2 %
en-on-ls-rs	12	4,2 %	100,0 %
es-on-ln-rn	11	3,8 %	54,5 %
es-os-ln-rn	11	3,8 %	81,8 %

Kreuzungstyp (Ground Truth)	Anzahl	Verteilung	Accuracy
en-on-ln-rd	10	3,5 %	90,0 %
en-od-ln-rn	10	3,5 %	60,0 %
ed-on-ln-rn	6	2,1 %	50,0 %
ed-od-ln-rn	5	1,7 %	20,0 %
en-on-ld-rd	3	1,0 %	66,7 %

Qualitative Fehlerverteilung (54 fehlgeschlagene Frames):

- **False Positives** (Geisterlinien bei NO_LINE): 30 / 54 **55,6 %**
- **Verpasste Linien / Falsche Typen** (bei Linien): 24 / 54 **44,4 %**

7.3.2 Auswertung und Diskussion

Die quantitative Analyse der aktuellen Konfiguration über die gesamte Teststrecke liefert eine globale Genauigkeit (Accuracy) von 81,12 %. Um diese Leistung korrekt einzuordnen, müssen die topologischen Eigenschaften der Teststrecke sowie die gewählte Evaluationsmetrik berücksichtigt werden.

STRECKENTOPOLOGIE UND KLASSENIMBALANCE Die Teststrecke umfasst Fahrscenarien, zu denen definitionsgemäß auch längere Abschnitte ohne Kreuzungen gehören, in denen lediglich die Standard-Fahrspuren existieren. Dies spiegelt sich drastisch in den Testdaten wider: Die Klasse NO_LINE bildet mit 205 von 286 Frames (71,7 %) die signifikante Mehrheit des Datensatzes.

Mit einer klassenspezifischen Accuracy von 85,4 % zeigt das System auf diesen reinen Spurabschnitten eine solide Basisstabilität. Dennoch entfallen aufgrund der massiven Klassendimbalace absolut gesehen die meisten Fehler auf diese Kategorie: 30 der insgesamt 54 Fehlklassifikationen (55,6 %) sind sogenannte False Positives innerhalb der NO_LINE-Klasse. Das System neigt hier dazu, fälschlicherweise Linienstrukturen (sogenannte „Geisterlinien“) zu detektieren, wo keine Kreuzung existiert.

STRIKTES LABELING Bei der Interpretation der Ergebnisse ist die methodische Strenge der Evaluierung zu betonen. Es wurde ein striktes Labeling-Verfahren angewendet,

bei dem jede Form von zeitlichem oder strukturellem „Flackern“ der Detektion (z. B. das kurzzeitige Verlieren einer Linie für nur einen einzelnen Frame) unmittelbar als vollständiger Fehler gewertet wurde.

Dieses Vorgehen erklärt das verhältnismäßig schlechte Abschneiden bei komplexeren Kreuzungstypen:

Der Typ ed-od-ln-rn (durchgezogene/gestrichelte Kombinationen) erreicht lediglich eine Accuracy von 20,0 % (5 Frames).

Der Typ ed-on-ln-rn bricht auf 50,0 % ein.

In realen Szenarien handelt es sich hierbei oft nicht um einen Totalausfall des Algorithmus, sondern um minimale Instabilitäten bei der Kantenzuordnung von Frame zu Frame. In der Challenge-Situation würde das Fahrzeug auf eine erfolgreiche Detektion reagieren und zum Halt kommen, auch wenn nach der Detektion die Erkennung des Systems leicht flackern würde.

7.4 Vollständige Fahrt mit First Contact Labeling

Um die vorige Bewertung realer zu gestalten, wird im Folgenden die Konfiguration so gewählt, dass ein einmaliges Erkennen der Ego-Linie (First-Contact) als valide Klassifikation gewertet wird. Das hat aus Sicht der CauDri-Challenge eine größere Aussagekraft, da das Fahrzeug bei erstmaliger Erkennung der Ego-Linie zum Halt kommt und sich dann die im Stehen die Erkennung aller anderen Linien verbessert. Hier wird nun nach erfolgreicher Erkennung der Ego-Linie und der erfolgreichen Erkennung der Kreuzung die gesamte Kreuzung als erkannt gewertet, auch wenn es in darauffolgenden Frames zu Flackern kommt.

7.4.1 Evaluation der Kreuzungserkennung (First Contact)

Analysierte Datensätze (\$N\$): 286

Globale Accuracy: 87,06 %

Kreuzungstyp (Ground Truth)	Anzahl	Verteilung	Accuracy
NO_LINE	209	73,1 %	86,1 %
en-on-ls-rs	15	5,2 %	100,0 %
es-on-ln-rn	12	4,2 %	66,7 %

Kreuzungstyp (Ground Truth)	Anzahl	Verteilung	Accuracy
ed-od-ln-rn	12	4,2 %	100,0 %
es-os-ln-rn	11	3,8 %	100,0 %
en-on-ln-rd	8	2,8 %	100,0 %
ed-on-ln-rn	8	2,8 %	87,5 %
en-on-ld-rd	5	1,7 %	60,0 %
en-os-ln-rn	4	1,4 %	100,0 %
en-on-ln-rs	2	0,7 %	50,0 %

Qualitative Fehlerverteilung (37 fehlgeschlagene Frames):

- **False Positives** (Geisterlinien bei NO_LINE): 29 / 37 **78,4 %**
- **Verpasste Linien / Falsche Typen** (bei Linien): 8 / 37 **21,6 %**

7.4.2 Auswertung der Evaluation First-Contact

Die Konfiguration „first contact“ erzielt eine signifikante Performanzsteigerung und hebt die globale Genauigkeit auf 87,06 % (+5,94 Prozentpunkte im Vergleich zur Baseline). Der entscheidende Durchbruch dieser Iteration liegt in der drastischen Reduktion von harten Klassifikationsfehlern bei tatsächlich existierenden Linien. Diese Fehlernatur sank von vormals 24 Frames auf lediglich 8 Frames (eine Reduktion um 66,7 %).

Besonders deutlich wird dieser Fortschritt bei komplexen Typen wie ed-od-ln-rn, deren Erkennungsrate von kritischen 20,0 % auf perfekte 100,0 % angehoben werden konnte. Das System erweist sich damit unter realen Linienbedingungen als hocheffektiv und weitgehend resistent gegenüber dem zuvor bemängelten „Flackern“.

Diese Resistenz wird unter anderem durch den bufferbasierten Aggregator bewerkstelligt, der Detektionen für mehrere Frames halten kann und damit Instabilitäten bei der Detektion eben dieser Kreuzungsarten (beispielsweise en-on-ls-rs oder en-on-ld-rd) ausgleichen. Gleichzeitig kann der Aggregator aber auch zu Fehlern führen, da dieser Klassifikationen zu lange im Buffer hält, auch wenn das Fahrzeug die bestimmte Fahrsituation schon durchfahren hat.

7.5 Datensatz 2

Es wird ein zweiter Datensatz einer anderen Fahrt genutzt ($N = 917$). bei dieser Fahrt haben sich im Vergleich zu Datensatz 1 die Lichtverhältnisse geändert. Außerdem ist die Kameraperspektive leicht verändert. Es ist zu Erwarten, dass vor allem durch die veränderte Kameraperspektive das System Haltelinien schlechter erkennt, da feste Thresholds eventuell True Positives als False Positives aussortieren oder durchgezogene Linien als gestrichelt wahrnehmen. Durch Tunen der Parameter können diese Fehler minimiert werden.

7.5.1 Evaluation der Kreuzungserkennung (Datensatz 2)

Analysierte Datensätze (N): 917

Globale Accuracy: 86,80 %

Kreuzungstyp (Ground Truth)	Anzahl	Verteilung	Accuracy
NO_LINE	733	79,9 %	94,4 %
es-os-ln-rn	44	4,8 %	22,7 %
ed-od-ln-rn	30	3,3 %	43,3 %
en-os-ln-rs	26	2,8 %	100,0 %
en-on-ls-rs	17	1,9 %	5,9 %
es-on-ln-rn	15	1,6 %	100,0 %
es-on-ls-rn	14	1,5 %	85,7 %
es-on-ln-rs	13	1,4 %	100,0 %
en-os-ls-rn	13	1,4 %	15,4 %
en-on-ln-rs	12	1,3 %	100,0 %

Qualitative Fehlerverteilung (121 fehlgeschlagene Frames):

- **False Positives** (Geisterlinien bei NO_LINE): 41 / 121 **33,9 %**
- **Verpasste Linien / Falsche Typen** (bei Linien): 80 / 121 **66,1 %**

7.5.2 Auswertung der Evaluation Datensatz 2

Das System zeigt in der ersten Evaluierungsphase unter konstanten Design-Bedingungen eine vielversprechende funktionale Performance. Insbesondere die anwendungsspezifische First-Contact-Metrik belegt mit einer globalen Accuracy von 87,06 % und einer fehlerfreien Erkennung kritischer Haltelinien (z. B. 100 % bei es-os-ln-rn), dass der Algorithmus für den gezielten Einsatz unmittelbar vor Kreuzungsbereichen mathematisch und funktional geeignet ist. Dieser positive Eindruck relativiert sich jedoch grundlegend, sobald das System mit veränderten Umgebungsbedingungen konfrontiert wird. Bei der Auswertung eines erweiterten, zweiten Datensatzes ($N = 917$) unter modifizierten Beleuchtungsverhältnissen und veränderten Kameraperspektiven sank die Erkennungsrate derselben Kreuzungsklasse (es-os-ln-rn) drastisch auf 22,7 %. Während die globale Accuracy bedingt durch den dominanten Anteil an Freistrecken (NO_LINE, 79,9 % Anteil) mit 86,80 % scheinbar stabil bleibt, offenbart die Detailanalyse eine kritische Blindheit des Systems gegenüber realen Linienstrukturen, da nun 66,1 % aller Fehlklassifikationen als False Negatives auftreten. Eine tiefergehende algorithmische Analyse dieser Sensitivität sowie die daraus resultierenden Systemgrenzen der klassischen Linienextraktion werden in der kritischen Würdigung (Abschnitt 8.1) dieser Arbeit detailliert erörtert.



Fazit

8.1 Kritische Reflexion

Innerhalb der Arbeit wurde ein System zur Klassifikation von Kreuzungen implementiert, welches für verschiedene Disziplinen innerhalb der CauDri-Challenge genutzt werden kann.

8.1.1 Positive Ergebnisse

Allgemein ist das Modul eine Verbesserung gegenüber dem zuvor genutzten Ansatz, bei dem eine festgelegte Strecke nach Erkennung des Schildes abgefahren wird. Das Modul erkennt die eigene Haltelinie und verhilft dem Fahrzeug somit zu einem sicheren Halt an der Kreuzung.

1. Durch eine Bildvorverarbeitungspipeline kann das System Reflexionen zu einem gewissen Grad herausfiltern, tatsächliche Haltelinienkandidaten für eine spätere Detektion hervorheben, verzerrte Linien glätten. Diese Pipeline ist ein stabiles System, welches auch für andere Module mit Liniendetektion genutzt werden kann.
2. Durch eine Kreuzungsmittenberechnung können Linienkandidaten den verschiedenen Haltelinien zugeordnet werden.
3. Innerhalb der Haltelinien kann zwischen durchgezogenen und gestrichelten Haltelinien unterschieden werden.
4. Durch Berechnung des Heading-Winkels werden Haltelinien auch aus der Kurve erkannt.

5. Durch ein Buffering System wird die Auswirkung von Flackern minimiert und die Stabilität des Ergebnisses erhöht.

Insgesamt ist das System bei ausreichendem Tuning von Schwellenwerten und Parametern robust, was es für die CauDri Challenge nutzbar macht.

8.1.2 Herausforderungen

Neben den positiven Ergebnissen des Systems konnten auch Herausforderungen festgestellt werden, die der klassische Ansatz während der Entwicklung und dem Testing hervorbrachte.

PARAMETRISIERUNG DES SYSTEMS Da es sich bei dieser Kreuzungserkennung um einen klassischen Ansatz handelt, müssen die Parameter des Systems vor dem Gebrauch angepasst werden. Bei der Auswertung in Abschnitt 7.5.2 ist hervorgekommen, dass das System bei Wechsel der Kameraperspektive und bei wechselnden Lichtverhältnissen (sonniger Tag entgegen bewölkter Tag) keine robuste Performance aufweist. Das liegt daran, dass das System mit festkodierten, aber anpassbaren Schwellenwerten und Parametern arbeitet, die Komponenten innerhalb des Systems dazu bewegen können, tatsächliche Haltelinien als False Positives auszufiltern oder False Positives als tatsächliche Haltelinien zu erkennen.

KAMERABEDINGTE VERZERRUNGEN Durch die Transformation des Bilds in die Vogelperspektive kam es im oberen Bereich der ROI zu starken Verzerrungen von Linien, wenn diese nicht genau waagerecht im Bild lagen. Waren diese leicht diagonal, wurden die Linien stufenartig dargestellt. Das war ein Problem für die Liniendetektion, konnte aber durch die Bildvorverarbeitungspipeline in großen Teilen behoben werden.

VERBESSERTE FALSE ALARM RATE Um die Anzahl an Falschdetektionen zu minimieren sind eine nicht unerhebliche Anzahl an Prüfmethode von Nöten, die Kandidaten herausfiltern. Falsche Detektion können die eigene Spur sein, die Spur der Querstraße, Fahrstreifenbegrenzungen oder Linien von Sperrflächen sein. Mit Prüfmethode konnten Falschalarme minimiert werden. Diese müssen parametrisiert werden (siehe Abschnitt 8.1.2.1).

SCHNELLIGKEIT DER PIPELINE Wie bereits beschrieben, besteht das System aus vielschichtigen Pipelines, die verschiedene Aufgaben erledigen und innerhalb der Haupt-

pipeline laufen. Außerdem wurde auch bereits beschrieben, dass viele Rechenschritte für das Herausfiltern von falschen Kandidaten und der Plausibilisierung von Ergebnissen genutzt werden. Die Laufzeit des Systems stellt kein Problem für den Betrieb im Fahrzeug dar, kann aber optimiert werden.

8.2 Ausblick

Das entwickelte System ist eine robuste Verbesserung gegenüber dem blinden Anfahren an Haltelinien. Es stellt einen ersten Schritt zu einer soliden Kreuzungserkennung dar, die das Fahrzeug innerhalb der CauDri-Challenge nutzen kann.

8.2.1 Erweiterungspotenzial

Um auf dem bestehenden System aufzubauen, kann es einige Schritte geben, um das System stabiler zu machen. Diese sind folgende:

1. Verbesserte Kreuzungsmittendetektion: Die Berechnung der Kreuzungsmitte erfolgt auf Basis der Shi-Tomasi Eckenerkennung und liefert unter Umständen Mitten, die leicht verschoben oder zu weit von der tatsächlichen Kreuzungsmitte liegen. Es könnte zu besseren Ergebnissen führen, die Parameter des Shi-Tomasi Algorithmus weiter zu optimieren. Es könnte außerdem auch ein Ansatz mit Fluchtpunktbildung getestet werden, welcher die Frontalsicht der Kamera nutzen müsste. Ferner kann ein modellbasierter Ansatz bessere Ergebnisse bringen.
2. Dynamische ROI: Mit einer dynamischen ROI könnte Falschdetektionen minimiert werden, ohne eine Vielzahl an regelbasierten Testalgorithmen zu nutzen.
3. Minimierung von Weißwertberechnungen: Komponenten wie das Erkennen von durchgezogenen oder gestrichelten Linien sowie das Filtern von False Positives wird durch Weißwertberechnungen gemacht, die stark von den aktuellen Lichtverhältnissen abhängen. Das funktioniert mit Anpassung von Parametern.

8.2.2 Langfristige Perspektiven

Langfristig können viele Verbesserungspotentiale des Systems durch Wechsel zu einem modellbasierten Ansatz gelöst werden. Es bleibt aus, die Performance eines solchen Systems zu evaluieren. Es könnte aber durch Generalisierung beim Training robust gegenüber Lichtinvarianzen und Kameraeinstellungen sein sowie die Anzahl an Testfunktionen zum Ausfiltern von False Positives minimieren. Dafür könnte man

ein YOLO-basiertes Modell (beispielsweise YOLO-World) verwenden und dieses auf Daten der Simulation sowie von aufgenommenen Rosbags trainieren [29].

A Literatur

- [1] CAuDri e.V., „CAuDri-Challenge Regulations 2026“. 2026. [Online]. Verfügbar unter: <https://www.caudri-challenge.de/regulations/>
- [2] A. bar hillel, R. Lerner, D. Levi, und G. Raz, „Recent progress in road and lane detection: A survey“, *Machine Vision and Applications*, Bd. 25, S. , 2014, doi: [10.1007/s00138-011-0404-2](https://doi.org/10.1007/s00138-011-0404-2).
- [3] C. Liu, Y. Liu, D. Hu, und X. Zhang, „SLSDNet: A Real-Time Stop-Line Detection Network Integrating the Line Segment Detection Method“, *IET Image Processing*, Bd. 19, Nr. 1, S. e70194, 2025, doi: <https://doi.org/10.1049/ipr2.70194>.
- [4] Y.-W. Seo und R. Rajkumar, „A vision system for detecting and tracking of stop-lines“, in *17th International IEEE Conference on Intelligent Transportation Systems (ITSC)*, 2014, S. 1970–1975. doi: [10.1109/ITSC.2014.6957994](https://doi.org/10.1109/ITSC.2014.6957994).
- [5] M. Aly, „Real time detection of lane markers in urban streets“, in *2008 IEEE Intelligent Vehicles Symposium*, IEEE, 2008, S. 7–12. doi: [10.1109/ivs.2008.4621152](https://doi.org/10.1109/ivs.2008.4621152).
- [6] G.-T. Lin, P. S. Santoso, C.-T. Lin, C.-C. Tsai, und J.-I. Guo, „Stop line detection and distance measurement for road intersection based on deep learning neural network“, in *2017 Asia-Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)*, 2017, S. 692–695. doi: [10.1109/APSIPA.2017.8282121](https://doi.org/10.1109/APSIPA.2017.8282121).
- [7] Smart Rollerz, „Technik — Smart Rollerz“. 2026.
- [8] T. Alsinet, Y. Petillot, J. Salvi, und X. Lladó, „The SLAM problem: a survey“, in *Artificial Intelligence Research and Development: Proceedings of the 11th International Conference of the Catalan Association for Artificial Intelligence*, 2008.
- [9] M. Reke u. a., „A self-driving car architecture in ROS2“, in *2020 International SAUPEC/RobMech/PRASA Conference*, 2020, S. 1–6.
- [10] A. Bonci, F. Gaudeni, M. C. Giannini, und S. Longhi, „Robot Operating System 2 (ROS2)-Based Frameworks for Increasing Robot Autonomy: A Survey“, *Applied Sciences*, Bd. 13, Nr. 23, 2023, doi: [10.3390/app132312796](https://doi.org/10.3390/app132312796).
- [11] OpenCV team, „Introduction to OpenCV — OpenCV 4.x Documentation“. 2026.
- [12] NumPy Developers, „What is NumPy? — NumPy v1.26 Manual“. 2026.

-
- [13] scikit-learn developers, „Getting Started — scikit-learn 1.4 Documentation“. 2026.
- [14] L.-W. Tsai, J.-W. Hsieh, C.-H. Chuang, und K.-C. Fan, „Lane detection using directional random walks“, in *2008 IEEE Intelligent Vehicles Symposium*, 2008, S. 303–306. doi: [10.1109/IVS.2008.4621271](https://doi.org/10.1109/IVS.2008.4621271).
- [15] E. S. Gedraite und M. Hadad, „Investigation on the effect of a Gaussian Blur in image filtering and segmentation“, in *Proceedings ELMAR-2011*, 2011, S. 393–396.
- [16] R. G. Gavaskar und K. N. Chaudhury, „Fast Adaptive Bilateral Filtering“, *IEEE Transactions on Image Processing*, Bd. 28, Nr. 2, S. 779–790, 2019, doi: [10.1109/TIP.2018.2871597](https://doi.org/10.1109/TIP.2018.2871597).
- [17] J. Beyerer, F. Puente León, C. Frese, und J. Meyer, „Vorverarbeitung und Bildverbesserung“, in *Automatische Sichtprüfung: Grundlagen, Methoden und Praxis der Bildgewinnung und Bildauswertung*, Berlin, Heidelberg: Springer Berlin Heidelberg, 2024, S. 639–708. doi: [10.1007/978-3-662-69951-5_10](https://doi.org/10.1007/978-3-662-69951-5_10).
- [18] P. Soille, „Opening and Closing“, in *Morphological Image Analysis: Principles and Applications*, Berlin, Heidelberg: Springer Berlin Heidelberg, 2004, S. 105–137. doi: [10.1007/978-3-662-05088-0_4](https://doi.org/10.1007/978-3-662-05088-0_4).
- [19] P. Musa, F. A. Rafi, und M. Lamsani, „A Review: Contrast-Limited Adaptive Histogram Equalization (CLAHE) methods to help the application of face recognition“, in *2018 Third International Conference on Informatics and Computing (ICIC)*, 2018, S. 1–6. doi: [10.1109/IAC.2018.8780492](https://doi.org/10.1109/IAC.2018.8780492).
- [20] Z. Xu, X. Baojie, und W. Guoxin, „Canny edge detection based on Open CV“, in *2017 13th IEEE international conference on electronic measurement & instruments (ICEMI)*, 2017, S. 53–56.
- [21] H. Agrawal und K. Desai, „Canny edge detection: A comprehensive review“, *International Journal of Technical Research & Science*, Bd. 9, Nr. Spl, S. 27–35, 2024.
- [22] R. Grompone von Gioi, J. Jakubowicz, J.-M. Morel, und G. Randall, „LSD: a Line Segment Detector“, *Image Processing On Line*, Bd. 2, S. 35–55, 2012.
- [23] R. O. Duda und P. E. Hart, „Use of the Hough transformation to detect lines and curves in pictures“, *Commun. ACM*, Bd. 15, Nr. 1, S. 11–15, Jan. 1972, doi: [10.1145/361237.361242](https://doi.org/10.1145/361237.361242).
- [24] D. Meng, W. Long, L. Hu, und L. Jiang, „Review on line detection of wood panel images“, *Advances in Engineering Innovation*, Bd. 5, S. 24–32, 2024.

-
- [25] H. Abdi und L. J. Williams, „Principal component analysis“, *WIREs Computational Statistics*, Bd. 2, Nr. 4, S. 433–459, 2010, doi: <https://doi.org/10.1002/wics.101>.
- [26] K. Khan, S. U. Rehman, K. Aziz, S. Fong, und S. Sarasvady, „DBSCAN: Past, present and future“, in *The Fifth International Conference on the Applications of Digital Information and Web Technologies (ICADIWT 2014)*, 2014, S. 232–238. doi: [10.1109/ICADIWT.2014.6814687](https://doi.org/10.1109/ICADIWT.2014.6814687).
- [27] R. Rochan M., A. Alagammai K., und S. J., „Computer Vision Based Novel Steering Angle Calculation for Autonomous Vehicles“, in *2018 Second IEEE International Conference on Robotic Computing (IRC)*, 2018, S. 143–146. doi: [10.1109/IRC.2018.00029](https://doi.org/10.1109/IRC.2018.00029).
- [28] R. F. Berriel u. a., „Heading Direction Estimation Using Deep Learning with Automatic Large-scale Data Acquisition“, in *2018 International Joint Conference on Neural Networks (IJCNN)*, 2018, S. 1–8. doi: [10.1109/IJCNN.2018.8489154](https://doi.org/10.1109/IJCNN.2018.8489154).
- [29] T. Cheng, L. Song, Y. Ge, W. Liu, X. Wang, und Y. Shan, „YOLO-World: Real-Time Open-Vocabulary Object Detection“, in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Juni 2024, S. 16901–16911.

B Glossar

Selbstständigkeitserklärung

Gemäß Ziffer 1.1.13 der Anlage 1 zu §§ 3, 4 und 5 der Studien- und Prüfungsordnung für die Bachelorstudiengänge im Studienbereich Technik der Dualen Hochschule Baden-Württemberg vom 29.09.2017. Ich versichere hiermit, dass ich meine Arbeit mit dem Thema:

Entwicklung eines klassischen Kreuzungsdetektors

selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Ich versichere zudem, dass alle eingereichten Fassungen übereinstimmen.

, 08.06.2026

Reinhold Brant